Sherlock

Lernen mit Gedächtnis

Ein Double-DQN-Agent für Lux AI Season 3

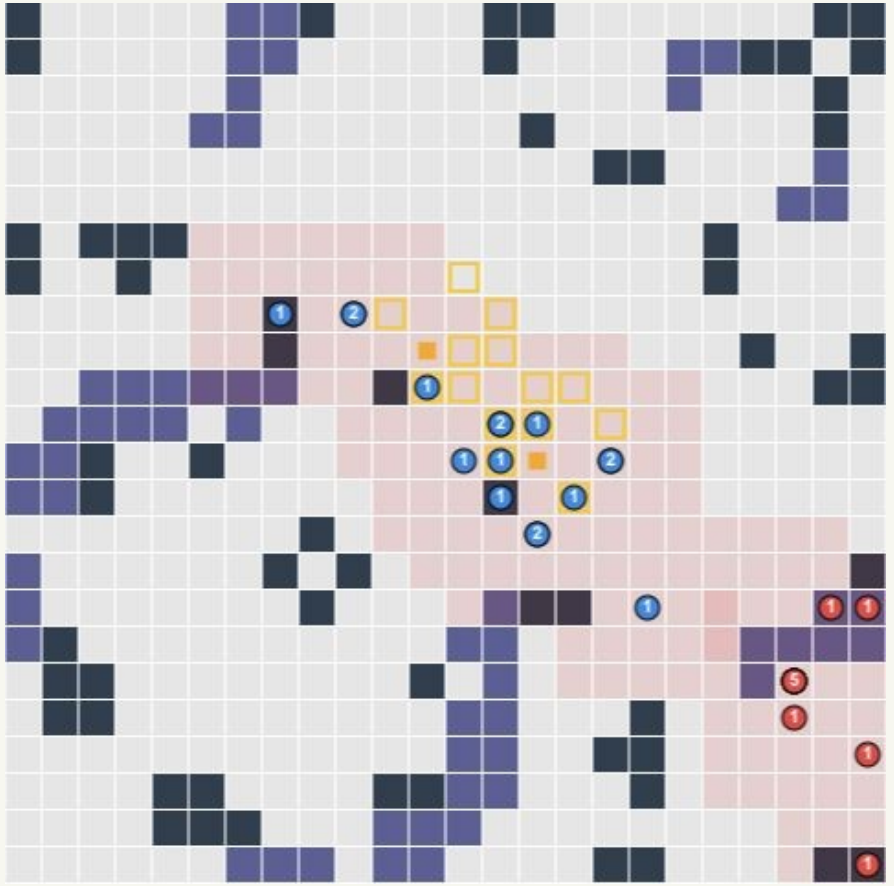
Mahmoud El-Hassan · Moayed Shawesh
HTW Berlin · Anwendungen der KI · 16.10.2026

Spielidee und Ziel

- **24 × 24 Felder**
- **Bis zu 16 Einheiten pro Team**

- Erkunden: Informationen fehlen
- Planen: Energie ist begrenzt
- Punkten: geeignete Felder besetzen

- **Kurs: 3 Matches je Spiel**



Unser Agent

01 **Merken**

Beobachtungen sammeln und Punktefelder erschließen.

02 **Bewerten**

Sechs trainierte Netze schätzen den Nutzen der Aktionen.

03 **Handeln**

Q-Werte mitteln; die beste erlaubte Aktion auswählen.

Merkmale und Gedächtnis

Merkmalsgruppe	Beispiele
Eigene Einheit	Position, Energie, mögliche Bewegung
Umgebung und Gedächtnis	Gelände, Relics, bekannte Punktefelder
Ziele und Gegner	Zielrichtung, Belegung, Sap-Möglichkeiten
Spielkontext	Matchfortschritt und Teamzustand

Belief: aus Beobachtungen Wissen über die Karte ableiten.

Netzarchitektur und Ensemble

79 → 256 → 256

Pro Einheit · gemeinsame MLP-Schichten mit ReLU

Dueling-Kopf	Schichten	Ausgabe
Zustandswert V	256 → 128 → 1	Ein Wert für die Situation
Aktionsvorteil A	256 → 128 → 6	Ein Wert pro Aktion

Ensemble: 3 × full + 3 × full_sym → Q-Mittelwert → Aktionsmaske

Double DQN

Vereinfachter Trainingsschritt

1 Ziehe Übergänge (s, a, r, s′, Ende) aus dem Buffer.
2 a* = beste erlaubte Folgeaktion laut Online-Netz
3 Ziel = r + γ · Q_Target(s′, a*) [ohne Folgewert bei Ende]
4 Passe Q_Online(s, a) an das Ziel an.
5 Kopiere das Online-Netz periodisch ins Target-Netz.

Belohnung: Punkte + Matchsieg + zusätzliche Shaping-Signale

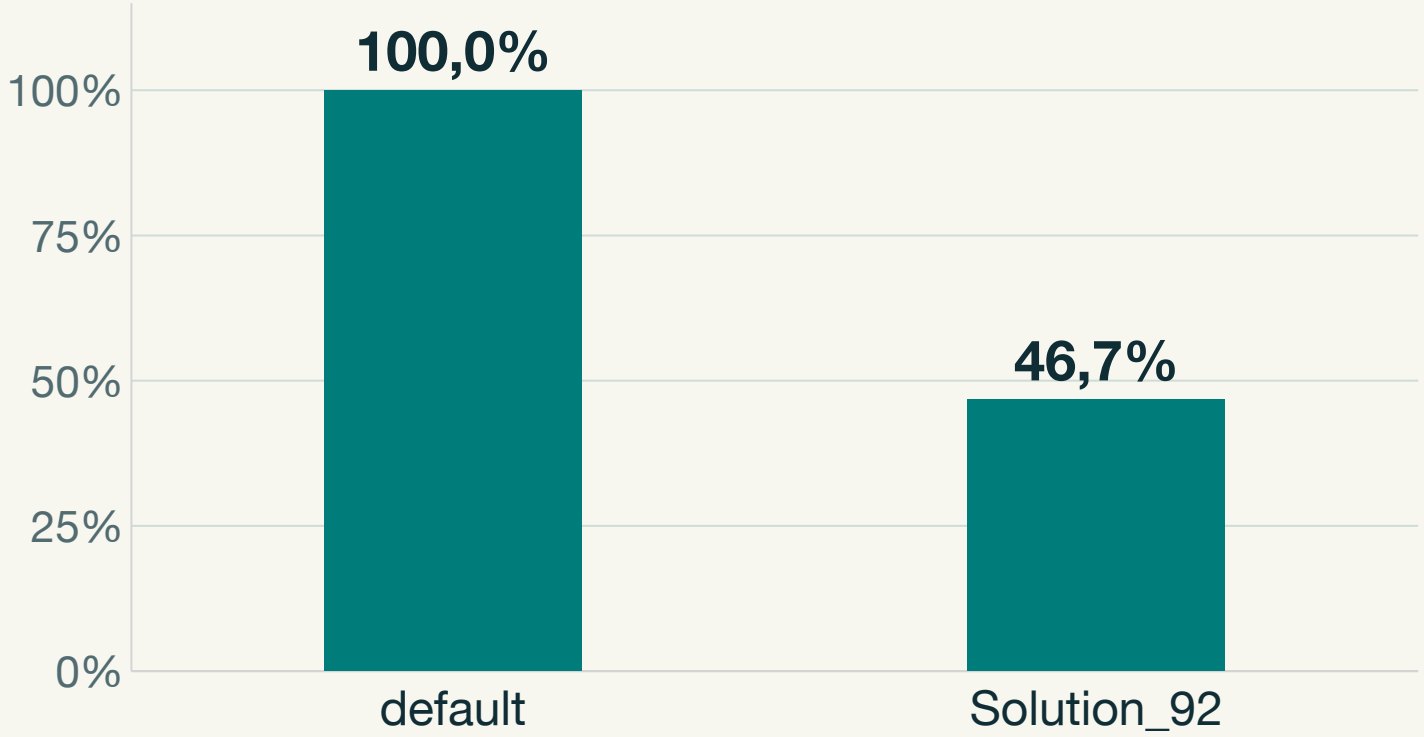
Training und Auswertung

6 × 3.000 = 18.000

Trainingsspiele der sechs Basisläufe des aktuellen Ensembles

Phase	Vorgehen
Training	Zuerst default; danach default und Solution_92
Validierung	Getrennte Karten; Checkpoints vergleichen
Auswertung	Beide Seiten; ε = 0; kein weiteres Lernen

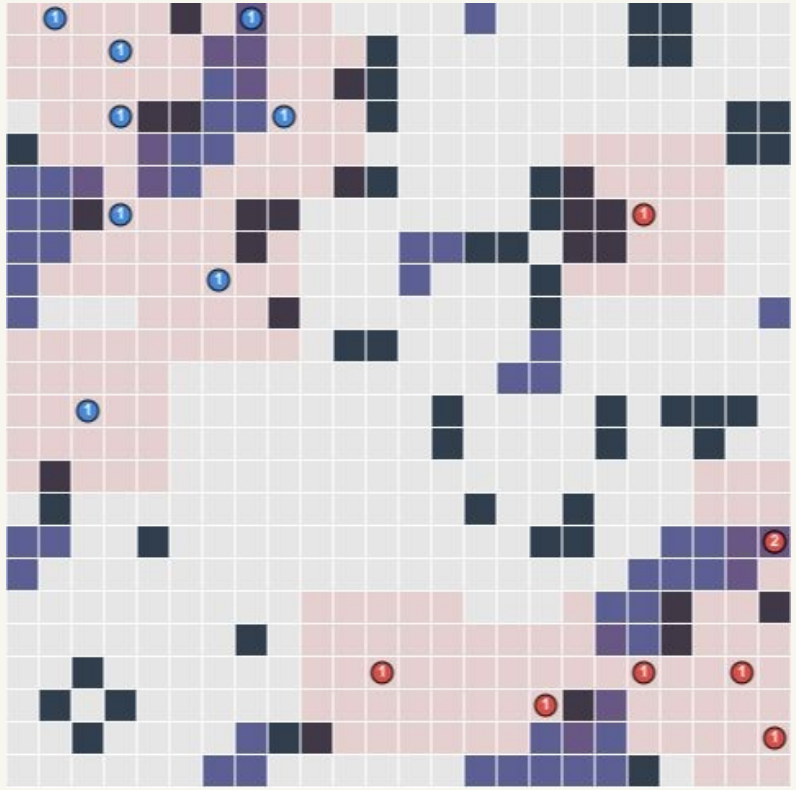
Benchmark-Ergebnisse



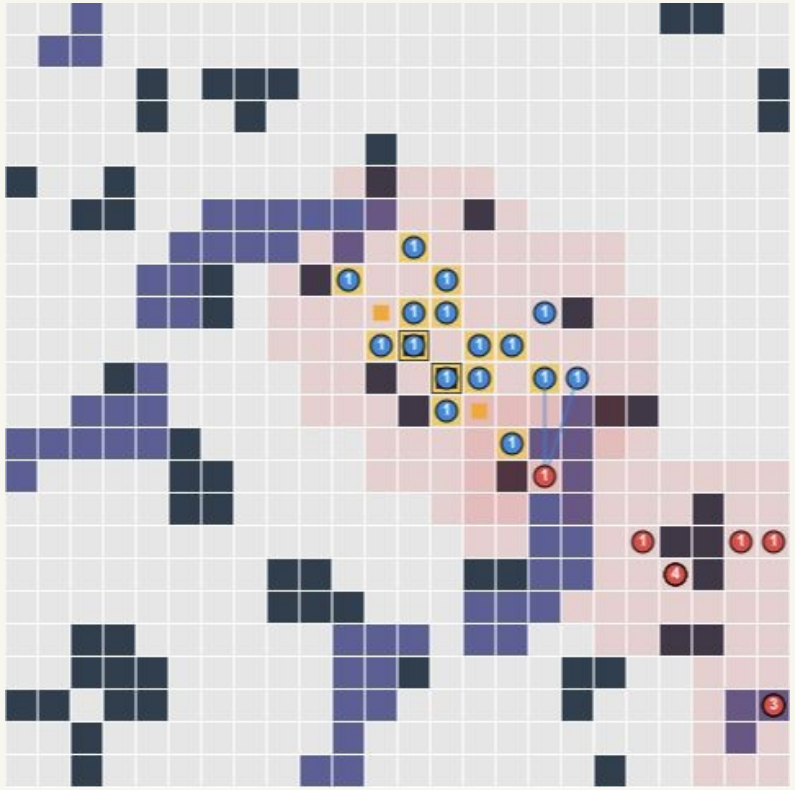
- **60 / 60 Siege gegen default**
- **28 / 60 Siege gegen Solution_92**

- Je Gegner: 30 Karten × 2 Seiten · bereits mehrfach genutzter Benchmark

Spielbeispiel



Schritt 23 · 0 : 0



Schritt 90 · 374 : 11

- **Sherlock: blau**
- **Gegner: rot**

- Blaue Einheiten besetzen Punktefelder
- Stehenbleiben kann sinnvoll sein

Seed 900011 · Match 1
Vollständige Replay-Ansicht

Erkenntnisse und Ausblick

01 **Beobachtung**

Weitertraining und Self-Play: bisher kein klarer Zusatzgewinn.

02 **Offene Hypothese**

Frühere Erkundung und Inferenz könnten Match 1 verbessern.

03 **Nächster Schritt**

Training absichern; m1_early prüfen; neue Testkarten zurückhalten.

Fazit und Fragen

Merken. Bewerten. Handeln.

- Trainierter Agent
- Nachvollziehbare Auswertung
- Klarer nächster Schritt

Fragen?

Trainingsparameter

Parameter	Wert
γ / Lernrate	0,99 / 0,0003
Batch / Buffer-Kapazität	256 / 300.000 Einheitenübergänge
Lernbeginn / Trainingsintervall	5.000 Übergänge / alle 2 Umgebungsschritte
Target-Kopie	Alle 500 Lernupdates
Exploration im Training	ε: 1,0 → 0,05 über 60.000 Umgebungsschritte

Gelernt und programmiert

Gelernt	Programmiert / festgelegt
Q-Werte und Aktionspräferenzen	Belief, Merkmale und Reward Shaping
Gewichte der sechs Netze	Zielzuweisung und erlaubte Aktionen
Bewertung der Aktion Sap	Konkretes Sap-Ziel
Entscheidung aus Netzbewertungen	Mittelwertbildung im Ensemble

Double DQN = Lernverfahren · Dueling = Architektur · Ensemble = Kombination