Sherlock

Lernen mit Gedächtnis

Ein Double-DQN-Agent für Lux AI Season 3

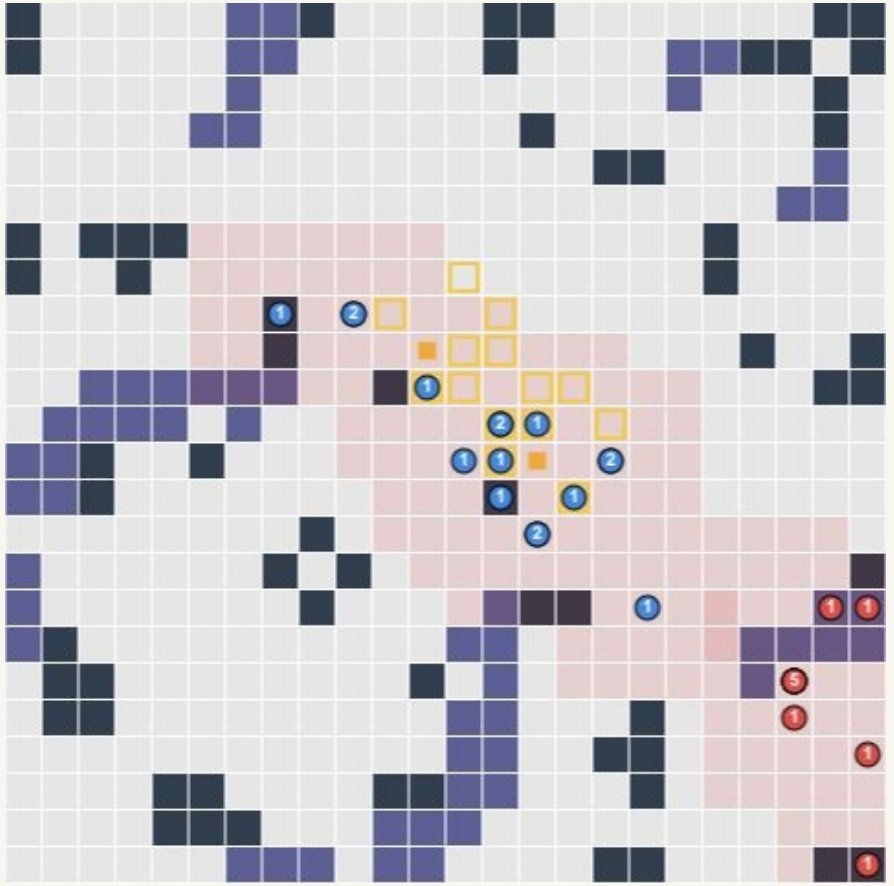
Mahmoud El-Hassan · Moayed Shawesh
HTW Berlin · Anwendungen der KI · 16.10.2026

Punkte finden, Felder halten, Matches gewinnen

24 × 24 Felder
Bis zu 16 Einheiten pro Team

Erkunden: Informationen fehlen.
Planen: Energie ist begrenzt.
Punkten: geeignete Felder besetzen.

Kurs: 3 Matches je Spiel



Sherlock verbindet Gedächtnis und Lernen

01 **Merken**

Beobachtungen sammeln und Punktefelder erschließen.

02 **Bewerten**

Sechs trainierte Netze schätzen den Nutzen der Aktionen.

03 **Handeln**

Q-Werte mitteln; die beste erlaubte Aktion auswählen.

79 Merkmale machen die Situation greifbar

Merkmalsgruppe	Beispiele
Eigene Einheit	Position, Energie, mögliche Bewegung
Umgebung und Gedächtnis	Gelände, Relics, bekannte Punktefelder
Ziele und Gegner	Zielrichtung, Belegung, Sap-Möglichkeiten
Spielkontext	Matchfortschritt und Teamzustand

Belief: aus Beobachtungen Wissen über die Karte ableiten.

Sechs Netze bewerten dieselben sechs Aktionen

79 → 256 → 256

Pro Einheit · gemeinsame MLP-Schichten mit ReLU

Dueling-Kopf	Schichten	Ausgabe
Zustandswert V	256 → 128 → 1	Ein Wert für die Situation
Aktionsvorteil A	256 → 128 → 6	Ein Wert pro Aktion

Ensemble: 3 × full + 3 × full_sym → Q-Mittelwert → Aktionsmaske

Double DQN: auswählen und bewerten trennen

Vereinfachter Trainingsschritt

1 Ziehe Übergänge (s, a, r, s′, Ende) aus dem Buffer.
2 a* = beste erlaubte Folgeaktion laut Online-Netz
3 Ziel = r + γ · Q_Target(s′, a*) [ohne Folgewert bei Ende]
4 Passe Q_Online(s, a) an das Ziel an.
5 Kopiere das Online-Netz periodisch ins Target-Netz.

Belohnung: Punkte + Matchsieg + zusätzliche Shaping-Signale

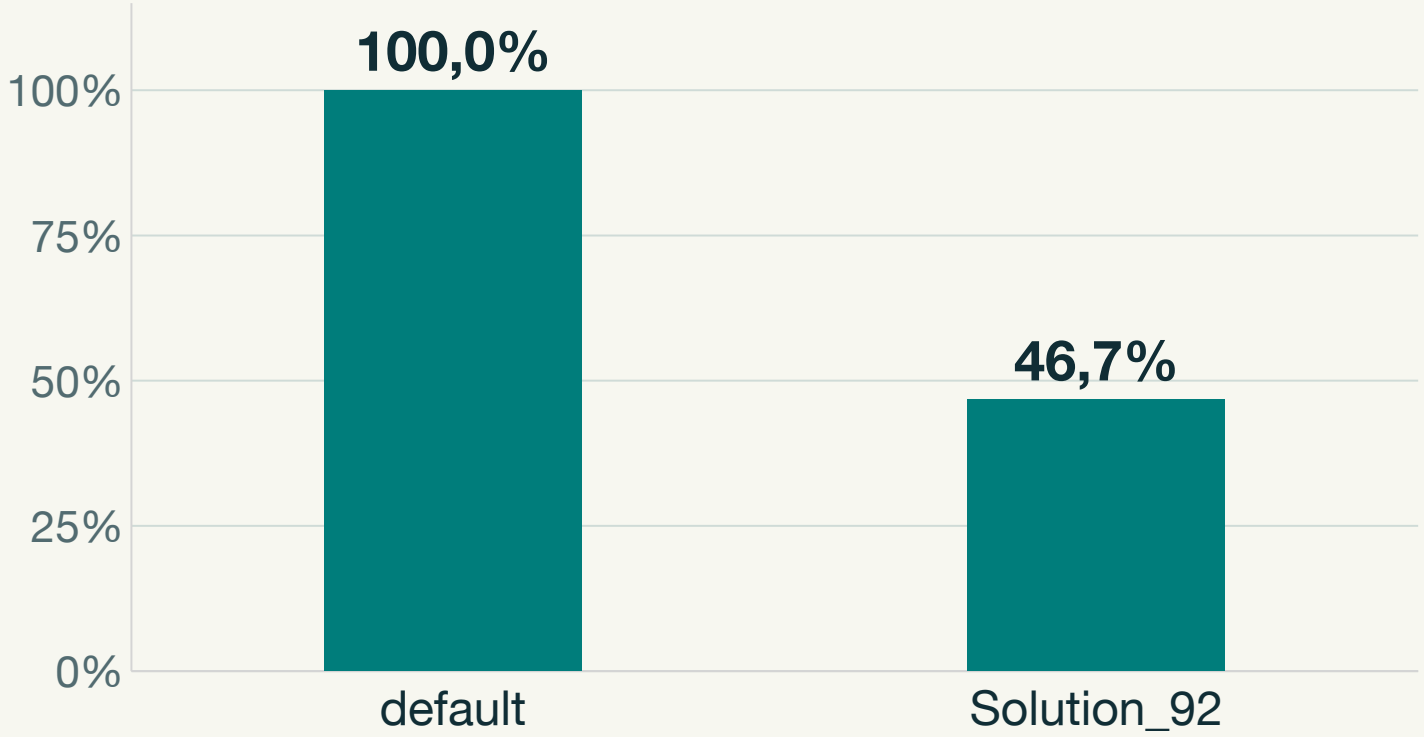
Sechs Trainingsläufe, danach feste Gewichte

6 × 3.000 = 18.000

Trainingsspiele der sechs Basisläufe des aktuellen Ensembles

Phase	Vorgehen
Training	Zuerst default; danach default und Solution_92
Validierung	Getrennte Karten; Checkpoints vergleichen
Auswertung	Beide Seiten; ε = 0; kein weiteres Lernen

Stark gegen default – der stärkere Gegner bleibt offen

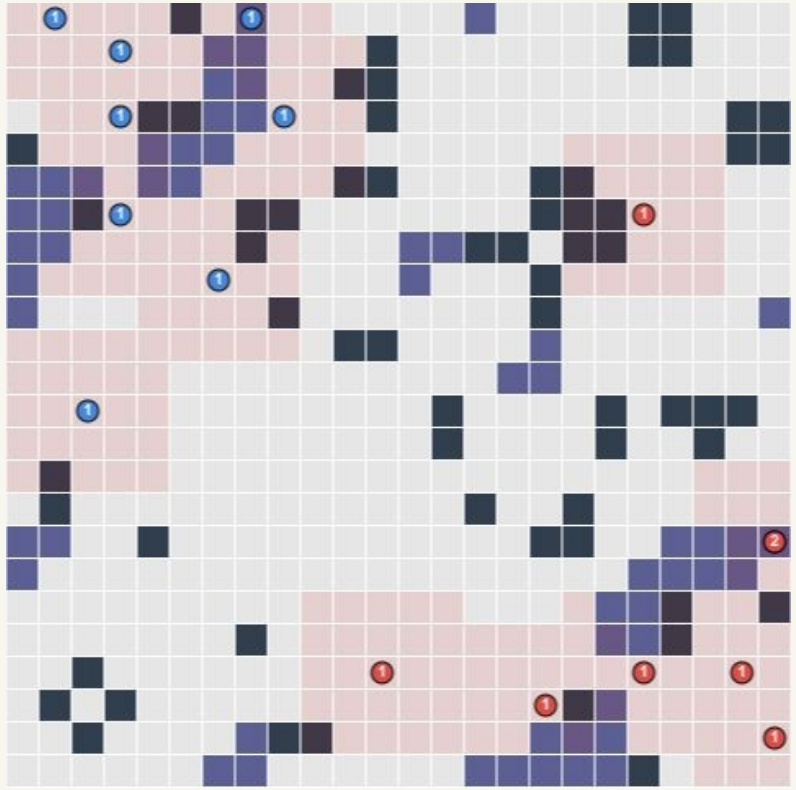


60 / 60 Siege
gegen default

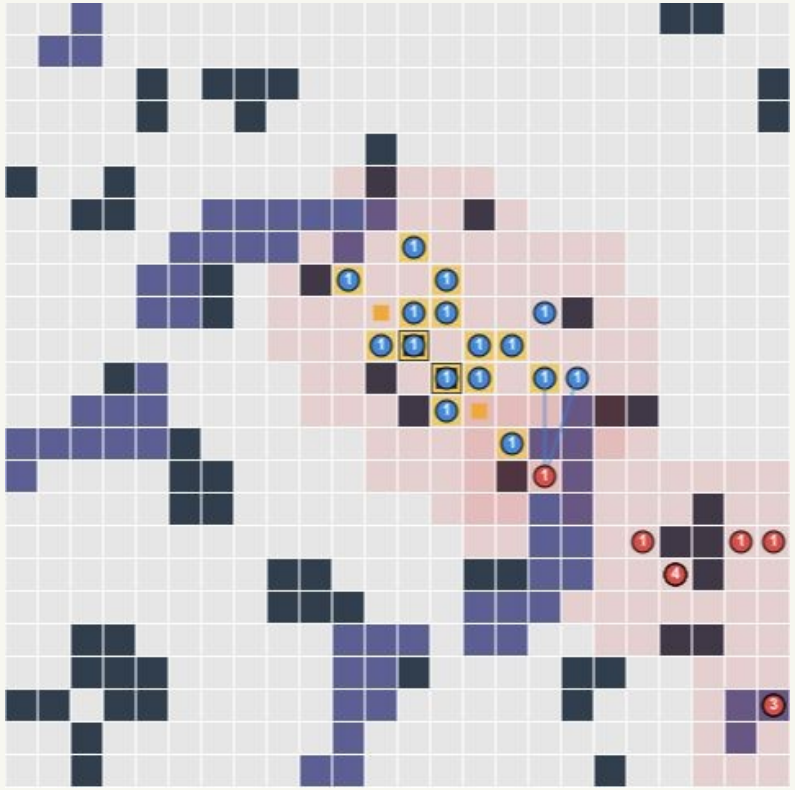
28 / 60 Siege
gegen Solution_92

Je Gegner: 30 Karten × 2 Seiten · bereits mehrfach genutzter Benchmark

Ein Spiel: erst verteilen, dann Punktefelder besetzen



Schritt 23 · 0 : 0



Schritt 90 · 374 : 11

Sherlock: blau
Gegner: rot

Blaue Einheiten besetzen Punktefelder.

Stehenbleiben kann eine gute Aktion sein.

Seed 900011 · Match 1
Vollständige Replay-Ansicht

Erkenntnisse und die nächsten Schritte

01 **Beobachtung**

Weitertraining und Self-Play: bisher kein klarer Zusatzgewinn.

02 **Offene Hypothese**

Frühere Erkundung und Inferenz könnten Match 1 verbessern.

03 **Nächster Schritt**

Training absichern; m1_early prüfen; neue Testkarten zurückhalten.

Sherlock hat eine tragfähige Grundlage

Merken. Bewerten. Handeln.

Trainierter Agent · nachvollziehbare Auswertung · klarer nächster Schritt

Fragen?

Trainingsparameter zum Nachschlagen

Parameter	Wert
γ / Lernrate	0,99 / 0,0003
Batch / Buffer-Kapazität	256 / 300.000 Einheitenübergänge
Lernbeginn / Trainingsintervall	5.000 Übergänge / alle 2 Umgebungsschritte
Target-Kopie	Alle 500 Lernupdates
Exploration im Training	ε: 1,0 → 0,05 über 60.000 Umgebungsschritte

Was wird gelernt – und was ist vorgegeben?

Gelernt	Programmiert / festgelegt
Q-Werte und Aktionspräferenzen	Belief, Merkmale und Reward Shaping
Gewichte der sechs Netze	Zielzuweisung und erlaubte Aktionen
Bewertung der Aktion Sap	Konkretes Sap-Ziel
Entscheidung aus Netzbewertungen	Mittelwertbildung im Ensemble

Double DQN = Lernverfahren · Dueling = Architektur · Ensemble = Kombination