Sherlock

Wie unser Agent entscheidet und wie wir ihn trainiert haben

18 gelernte Netze entscheiden, Gedächtnis und Regeln helfen ihnen.
90 % gegen Solution_92

Mahmoud El-Hassan · Moayed Shawesh
HTW Berlin · Anwendungen der KI · 06.11.2026

Agenda

1. Was Sherlock bekommt und zurückgibt
2. Ein Spielschritt: Gedächtnis, Netze, Maske, Regeln
3. Training der 18 Netze
4. Von 47 % auf 90 %
5. Neu seit letzter Woche
6. Erkenntnisse und Battle

Was Sherlock bekommt und zurückgibt

Eingang in jedem Schritt

- Sichtbare Einheiten beider Teams: Position, Energie
- Sichtbare Felder: Energie, Nebel, Asteroid
- Sichtbare Relics
- Punkte im Match, gewonnene Matches, Schrittzähler
- **Unsichtbar: welche Felder Punkte bringen**

→

Sherlock

höchstens 11,4 ms pro Schritt

→

Ausgang

16 × 3 Zahlen, je Einheit **[Aktion, dx, dy]**

0	stehen
1–4	hoch, rechts, runter, links
5	Sap (Schuss) auf Feld (dx, dy)

Einmal pro Spiel kommen Zugkosten, Sap-Kosten, Sap-Reichweite und Sichtweite dazu. Verdeckte Werte wie den Energieabzug im Nebel schätzt Sherlock aus den Energieverläufen der eigenen Einheiten.

Ein Spielschritt: wer macht was?

1
Gedächtnis
Karte, Relics und Punktefelder über alle 3 Matches
PROGRAMMIERT

→

2
Ziele
jede Einheit ein eigenes Ziel, nach Weglänge verteilt
PROGRAMMIERT

→

3
Merkmale
79 Zahlen je Einheit: Lage, Ziel, Umgebung, Gegner
PROGRAMMIERT

→

4
18 Netze
bewerten die 6 Aktionen mit Q-Werten, wir mitteln
GELERNT (DQN)

→

5
Maske
verbotene Aktionen streichen, beste erlaubte nehmen
PROGRAMMIERT

→

6
Regeln
korrigieren Sackgassen, Nebel, doppelte Schüsse
PROGRAMMIERT

→ **16 × 3 Aktionen ans Spiel.** Das Netz entscheidet **was** eine Einheit tut, beim Sap auch **ob** geschossen wird. **Wohin** geschossen wird, berechnet eine Formel: das Feld mit der meisten getroffenen Gegnerenergie.

Gedächtnis: Welche Felder bringen Punkte?

Beispiel für einen Schritt

Punktezuwachs in diesem Schritt	3
besetzte Felder	4
davon schon bewiesene Punktefelder	2

Also: von den 2 übrigen Feldern bringt genau 1 einen Punkt

- Solche Gleichungen werden gesammelt, bis sie eindeutig sind
- Die Karte ist spiegelsymmetrisch: ein bewiesenes Feld gilt auch für sein Spiegelfeld
- Asteroiden und Nebel wandern: das Gedächtnis erkennt die Drift und verschiebt die Karte mit
- Alles bleibt über die 3 Matches eines Spiels erhalten

Die Punktefelder sieht kein Agent direkt. Das Spiel zeigt nur, wie viele Punkte das Team im Schritt bekommen hat.

Action Masking: nur erlaubte Aktionen

Aktion	erlaubt, wenn …
Stehen	immer
Zug	genug Energie, Zielfeld auf der Karte, kein Asteroid
Zug, im Spiel	zusätzlich kein mindestens gleich starker Gegner auf oder neben dem Zielfeld
Sap	Gegner in Reichweite und genug Energie

- Verboten heißt: Q-Wert = −∞, die Aktion wird nie gewählt
- Im Training gilt dasselbe für Zufallszüge und das Lernziel

Echtes Beispiel: Einheit vor einem Asteroiden

stehen	47,4	
hoch	47,8	
rechts	**48,6**	**✓ gespielt**
runter	~~50,4~~	✗ Asteroid
links	~~47,4~~	✗ Kartenrand
Sap	~~42,2~~	✗ kein Gegner

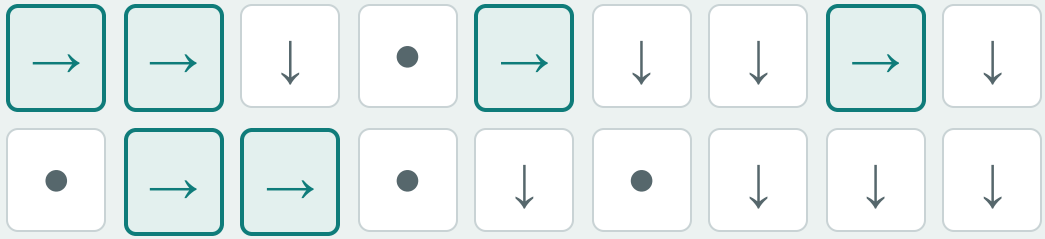
Mittel der 18 Netze. Am liebsten „runter“, das ist aber verboten.

Gemessen in 36.258 Entscheidungen: im Mittel 4,3 von 6 Aktionen erlaubt; in 20 % war die Lieblingsaktion der Netze verboten (10 Spiele gegen Solution_92, 5 Karten × beide Seiten).

18 Netze entscheiden gemeinsam

- **Keine Aufteilung auf Spiele:** alle 18 Netze bewerten jede Einheit in jedem Schritt
- Gleiche Bauart: 79 → 256 → 256 → 6 Q-Werte (Dueling-DQN, 153.000 Parameter je Netz)
- Ein Netz für alle Einheiten und beide Seiten: die Karte wird für Spieler 2 gespiegelt
- Q-Werte je Aktion mitteln → beste erlaubte Aktion
- **Warum 18?** Einzelne Netze schwanken stark, der Mittelwert glättet. 30 Netze waren nicht besser.

Echtes Beispiel: die 18 Netze sind uneinig



→ rechts **6** ↓ runter **8** • stehen **4**

Mehrheit wäre **runter**. Der Mittelwert wählt **rechts** (25,9 vor 25,8), weil er zählt, **wie sicher** sich jedes Netz ist.

In den 36.258 gemessenen Entscheidungen: alle 18 Netze einig in 32 %; im Mittel wählen 13,4 von 18 Netzen einzeln dieselbe Aktion wie das Ensemble; Mittelwert und Mehrheitswahl unterscheiden sich in 8 %.

So wurden die 18 Netze trainiert

Gruppe	Netze	Spiele je Netz	Gegner nach 25 % Aufwärmen gegen default
A	6	3.000	abwechselnd default und Solution_92
B	6	4.000	70 % Solution_92, Rest default
C	6	4.000	60 % Solution_92, 20 % eigene alte Agenten; Strafe für Gegnerpunkte

- **66.000 Trainingsspiele**, je Netz eigener Zufallsstart und eigene Karten
- Double DQN mit Target-Netz und Replay Buffer (300.000 Übergänge)
- Belohnung **in jedem Schritt pro Einheit**: Punktefeld halten, Annäherung ans Ziel, Erkunden, Matchsieg; Strafe für Tod
- Verwendet wird der Endstand jedes Laufs

Das Netz entscheidet, Regeln sichern ab

92 %

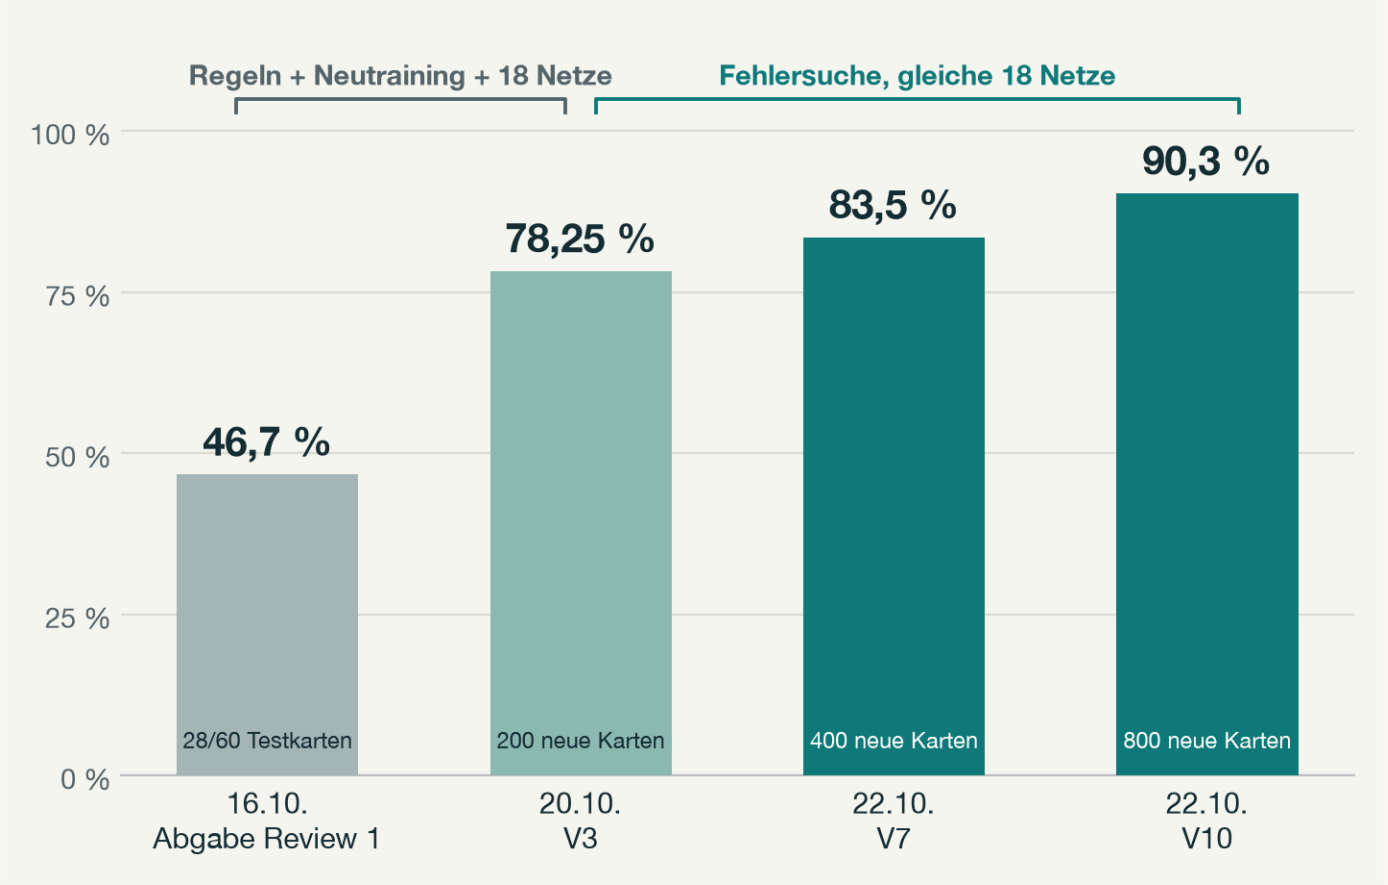
der Entscheidungen spielt Sherlock genau so, wie die Netze sie getroffen haben

Eine einfache Regel statt der Netze gewann am 19.10. nur 3 % gegen Solution_92, mit Netzen 38 %.

Regel greift ein	Anteil
Nur Erkundungsziel: direkt hinlaufen statt warten	4,3 %
Schädlichen Nebel umgehen	1,2 %
Kein Schuss auf ein schon sicher getroffenes Ziel	0,9 %
Sackgasse: kürzesten Weg nehmen	0,6 %
Auf dem Punktefeld stehen und schießen	0,5 %
Aus sicherer Entfernung in eine Gruppe schießen	0,25 %

Anteile an 36.258 Entscheidungen in 10 Spielen gegen Solution_92. Zusammen ändern die Regeln 7,3 % der Aktionen.

Von 47 % auf 90 % gegen Solution_92



Siegquote gegen Solution_92 auf neuen Karten, beide Seiten; V10 auf 800 Karten.

BIS 78 %: TRAINING UND REGELN

Neu trainiert mit aktiven Regeln, 18 statt 6 Netze, Regeln für Suche, Ziele und Schüsse

78 → 90 %: FEHLERSUCHE

Verlorene Spiele mit dem wahren Spielzustand verglichen:

- Karte im Gedächtnis veraltet (18 % falsch)
- Sackgassen, unerreichbare Ziele
- Mehrfachschüsse, Kollisionen

Seit dem 20.10. dieselben 18 Netze

Neu seit letzter Woche

Liga-Training: robuster gegen andere Teams?

- 6 neue Netze × 4.000 Spiele, alle Regeln schon im Training aktiv
- Gemischte Gegner: 40 % Solution_92, 20 % Solution_92 mit Quadrat-Schuss, 20 % alte Sherlocks, 15 % default, 5 % Rush-Bot
- Ergebnis: **+0,8 Punkte** (95 %: −1,4 bis +3,1), Hürde +1,5 verfehlt; direkt gegen V10 52,5 %
- → **nicht übernommen, V10 bleibt**

V10 gegen andere Spielweisen

default	**100 %**
Solution_92, zielt auf die schwächste Einheit	**90,5 %**
Solution_92	**90,2 %**
Unsere Abgabe vom 16.10.	**89,9 %**
Solution_92, schießt im ganzen Quadrat	**78,9 %**

je 1.600 Spiele (800 neue Karten, beide Seiten)

Außerdem: Abgabe für heute in der Original-Kursvorlage getestet. Dabei einen Ladefehler gefunden und behoben: Mit dem Ordner unter *agents/* und dem Pfad *Gruppe15/agent.pth* hätte Sherlock seine Gewichte nicht gefunden und untrainiert gespielt.

Erkenntnisse

01 Das Gelernte trägt

92 % der Aktionen kommen unverändert aus den Netzen. Eine einfache Regel statt der Netze gewann nur **3 %** statt 38 %.

02 Ab 78 % war Training nicht mehr der Engpass

CNN + PPO, neue Merkmale und weitere Netze brachten keinen Gewinn. Fehler im Agenten finden brachte **78 → 90 %**.

03 Jede Idee auf neuen Karten prüfen

Hürden vorab festlegen. Beispiel: eine Energie-Korrektur lag in der Auswahl vorn, auf 1.600 neuen Spielen dann 0,7 Punkte hinten.

Fazit und Battle

Gelernt entscheiden, programmiert absichern

Im Replay achten auf:

- Einheiten verteilen sich auf verschiedene Ziele
- Einheiten auf Punktefeldern bleiben stehen und schießen nur auf stehende Gegner
- Schädlicher Nebel wird umgangen

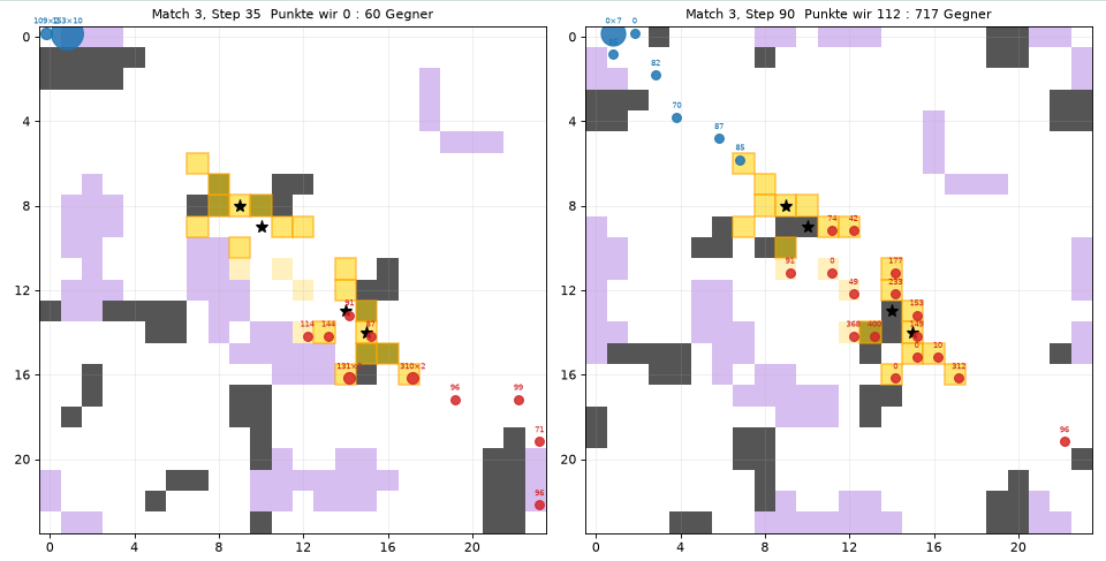
Fragen?

Reserve: So prüfen wir

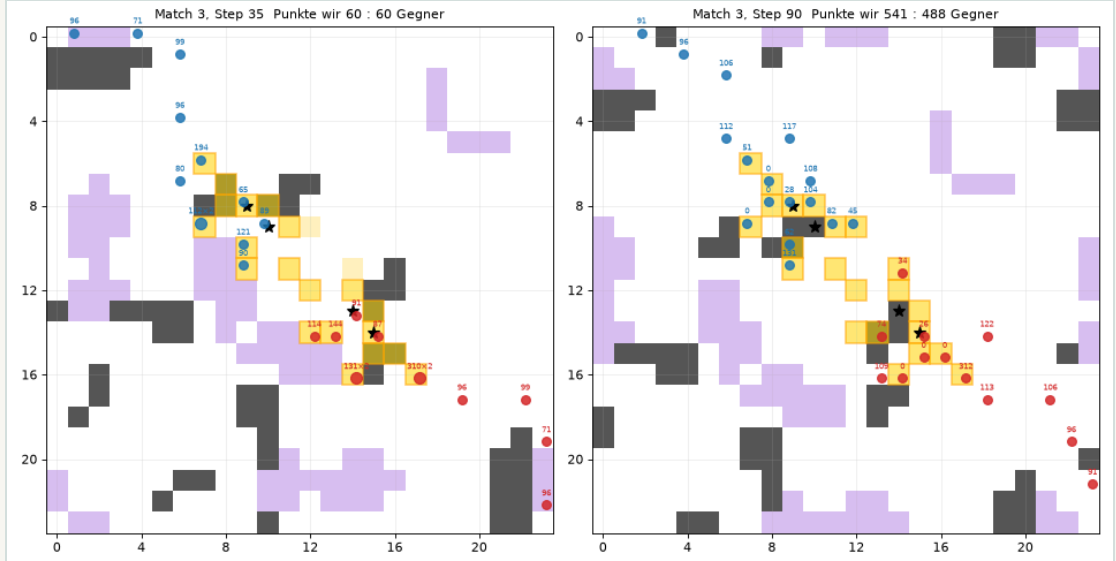
- **Entwicklung:** 2.000 neue Karten nach dem Ergebnis von V3 in schwer und leicht geteilt; daraus 330 schwere und 335 leichte Karten, beide Seiten (1.330 Spiele). Gesamtschätzung = 0,33 · schwer + 0,67 · leicht; sie traf die späteren frischen Werte auf etwa einen Punkt.
- **Übernahme nur, wenn alle Hürden erfüllt sind** (vorab festgelegt): gegen Solution_92 mindestens +2 Punkte mit 95 %-Untergrenze über 0; default mindestens 99 %; direkt gegen die Abgabe mit Untergrenze über 50 %.
- **Statistik:** gepaarter Bootstrap über ganze Karten (beide Seiten zusammen), 5.000 Ziehungen.
- **Frische Karten:** jeder Block nur einmal benutzt; Abgabe-Gewichte vor jeder Übernahme mit Prüfsumme gesichert.

Reserve: Fehler 1: Die Karte im Gedächtnis war veraltet

Sherlock · Solution_92 · Punktefeld · Asteroid · Nebel · ★ Relic · Zahl = Energie · Karte 360014, Match 3



Vorher: Einheiten am Start eingesperrt · Schritt 90: 112 : 717



Nachher: Einheiten verlassen sofort den Start · Schritt 90: 541 : 488

- Asteroiden und Nebel wandern, Nebel ist bei kleiner Sicht unsichtbar → **18 % der gemerkten Felder waren falsch**
- Lösung: Drift erkennen und Karte mitrollen; unsichtbar trotz Sichtweite heißt Nebel → 210 von 210 Drifts erkannt

Reserve: Spielregeln, die wir nutzen

Sap (Schuss)	im ganzen Quadrat bis zur Reichweite (3–7); Ziel verliert die Schusskosten, Nachbarfelder einen Anteil (Streufaktor 0,25 / 0,5 / 1)
Kollision	Stehen Einheiten beider Teams auf einem Feld, überlebt nur das Team mit mehr Gesamtenergie; bei Gleichstand sterben beide
Energie-Sog	Benachbarte Gegner ziehen Energie ab (Faktor verdeckt, 1/16 bis 3/8)
Drift	Asteroiden und Nebel verschieben sich alle 7–40 Schritte diagonal
Relics	bis zu drei Paare; ein neues Paar kann in Match 2 und 3 in den ersten 50 Schritten erscheinen