Sherlock

Wie unser Agent entscheidet und wie wir ihn trainiert haben

36 gelernte Netze entscheiden, Gedächtnis und Regeln helfen ihnen.
94 % gegen Solution_92

Mahmoud El-Hassan · Moayed Shawesh
HTW Berlin · Anwendungen der KI · 06.11.2026

Agenda

1. Was Sherlock bekommt und zurückgibt
2. Ein Spielschritt: Gedächtnis, Netze, Maske, Regeln
3. Training der Netze
4. Von 47 % auf 94 %
5. Neu seit letzter Woche
6. Erkenntnisse und Battle

Was Sherlock bekommt und zurückgibt

Eingang in jedem Schritt

- Sichtbare Einheiten beider Teams: Position, Energie
- Sichtbare Felder: Energie, Nebel, Asteroid
- Sichtbare Relics
- Punkte im Match, gewonnene Matches, Schrittzähler
- **Unsichtbar: welche Felder Punkte bringen**

→

Sherlock

höchstens 8,8 ms pro Schritt

→

Ausgang

16 × 3 Zahlen, je Einheit **[Aktion, dx, dy]**

0	stehen
1–4	hoch, rechts, runter, links
5	Sap (Schuss) auf Feld (dx, dy)

Einmal pro Spiel kommen Zugkosten, Sap-Kosten, Sap-Reichweite und Sichtweite dazu. Verdeckte Werte wie den Energieabzug im Nebel oder den Streuschaden beim Sap schätzt Sherlock aus den Energieverläufen der eigenen Einheiten.

Ein Spielschritt: wer macht was?

1
Gedächtnis
Karte, Relics und Punktefelder über alle 3 Matches
PROGRAMMIERT

→

2
Ziele
jede Einheit ein eigenes Ziel, nach Weglänge verteilt
PROGRAMMIERT

→

3
Merkmale
79 Zahlen je Einheit: Lage, Ziel, Umgebung, Gegner
PROGRAMMIERT

→

4
36 Netze
bewerten die 6 Aktionen mit Q-Werten, wir mitteln
GELERNT (DQN)

→

5
Maske
verbotene Aktionen streichen, beste erlaubte nehmen
PROGRAMMIERT

→

6
Regeln
korrigieren Sackgassen, Nebel, doppelte Schüsse
PROGRAMMIERT

→ **16 × 3 Aktionen ans Spiel.** Das Netz entscheidet **was** eine Einheit tut, beim Sap auch **ob** geschossen wird. **Wohin** geschossen wird, berechnet eine Formel: das Feld mit der meisten getroffenen Gegnerenergie.

Gedächtnis: Welche Felder bringen Punkte?

Beispiel für einen Schritt

Punktezuwachs in diesem Schritt	3
besetzte Felder	4
davon schon bewiesene Punktefelder	2

Also: von den 2 übrigen Feldern bringt genau 1 einen Punkt

- Solche Gleichungen werden gesammelt, bis sie eindeutig sind
- Die Karte ist spiegelsymmetrisch: ein bewiesenes Feld gilt auch für sein Spiegelfeld
- Asteroiden und Nebel wandern: das Gedächtnis erkennt die Drift und verschiebt die Karte mit
- Alles bleibt über die 3 Matches eines Spiels erhalten

Die Punktefelder sieht kein Agent direkt. Das Spiel zeigt nur, wie viele Punkte das Team im Schritt bekommen hat.

Action Masking: nur erlaubte Aktionen

Aktion	erlaubt, wenn …
Stehen	immer
Zug	genug Energie, Zielfeld auf der Karte, kein Asteroid
Zug, im Spiel	zusätzlich kein mindestens gleich starker Gegner auf oder neben dem Zielfeld
Sap	Gegner in Reichweite und genug Energie

- Verboten heißt: Q-Wert = −∞, die Aktion wird nie gewählt
- Im Training gilt dasselbe für Zufallszüge und das Lernziel

Echtes Beispiel: Einheit vor einem Asteroiden

stehen	51,0	
hoch	51,3	
rechts	**52,2**	**✓ gespielt**
runter	~~53,8~~	✗ Asteroid
links	~~51,2~~	✗ Kartenrand
Sap	~~47,6~~	✗ kein Gegner

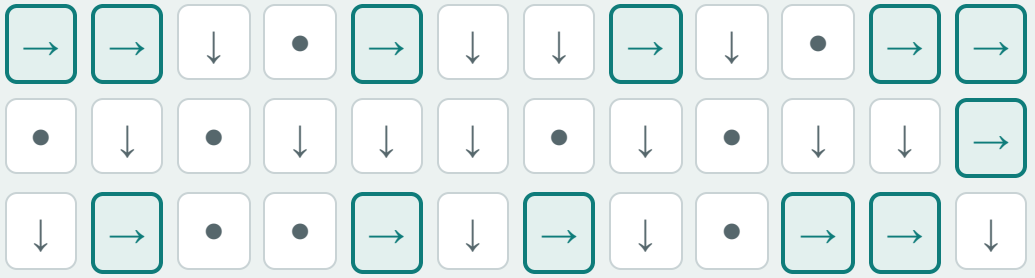
Mittel der 36 Netze. Am liebsten „runter“, das ist aber verboten.

Gemessen in 36.209 Entscheidungen: im Mittel 4,3 von 6 Aktionen erlaubt; in 22 % war die Lieblingsaktion der Netze verboten (10 Spiele gegen Solution_92, 5 Karten × beide Seiten).

36 Netze entscheiden gemeinsam

- **Keine Aufteilung auf Spiele:** alle 36 Netze bewerten jede Einheit in jedem Schritt
- Gleiche Bauart: 79 → 256 → 256 → 6 Q-Werte (Dueling-DQN, 153.000 Parameter je Netz)
- Ein Netz für alle Einheiten und beide Seiten: die Karte wird für Spieler 2 gespiegelt
- Q-Werte je Aktion mitteln → beste erlaubte Aktion
- **Warum 36?** 18 Netze vom 20.10. und dieselben 18 nachtrainiert. Gemischt besser als jede Hälfte allein.

Echtes Beispiel: die 36 Netze sind uneinig



→ rechts **12** ↓ runter **15** • stehen **9**

Mehrheit wäre **runter**. Der Mittelwert wählt **rechts** (27,0 vor 26,9), weil er zählt, **wie sicher** sich jedes Netz ist.

In den 36.209 gemessenen Entscheidungen: alle 36 Netze einig in 31 %; im Mittel wählen 27,4 von 36 Netzen einzeln dieselbe Aktion wie das Ensemble; Mittelwert und Mehrheitswahl unterscheiden sich in 6 %.

So wurden die 36 Netze trainiert

Gruppe	Netze	Spiele je Netz	Gegner nach 25 % Aufwärmen gegen default
A	6	3.000	abwechselnd default und Solution_92
B	6	4.000	70 % Solution_92, Rest default
C	6	4.000	60 % Solution_92, 20 % eigene alte Agenten; Strafe für Gegnerpunkte
Nach-training	18 Kopien	+ 5.500	alle heutigen Regeln aktiv; 70 % Solution_92 und zwei Varianten, 20 % eigene Abgaben, Rest default und Rush-Bot

- **66.000 + 99.000 Trainingsspiele**, je Netz eigener Zufallsstart und eigene Karten
- Double DQN mit Target-Netz und Replay Buffer (300.000 Übergänge)
- Belohnung **in jedem Schritt pro Einheit**: Punktefeld halten, Annäherung ans Ziel, Erkunden, Matchsieg; Strafe für Tod
- Verwendet wird der Endstand jedes Laufs

Das Netz entscheidet, Regeln sichern ab

92 %

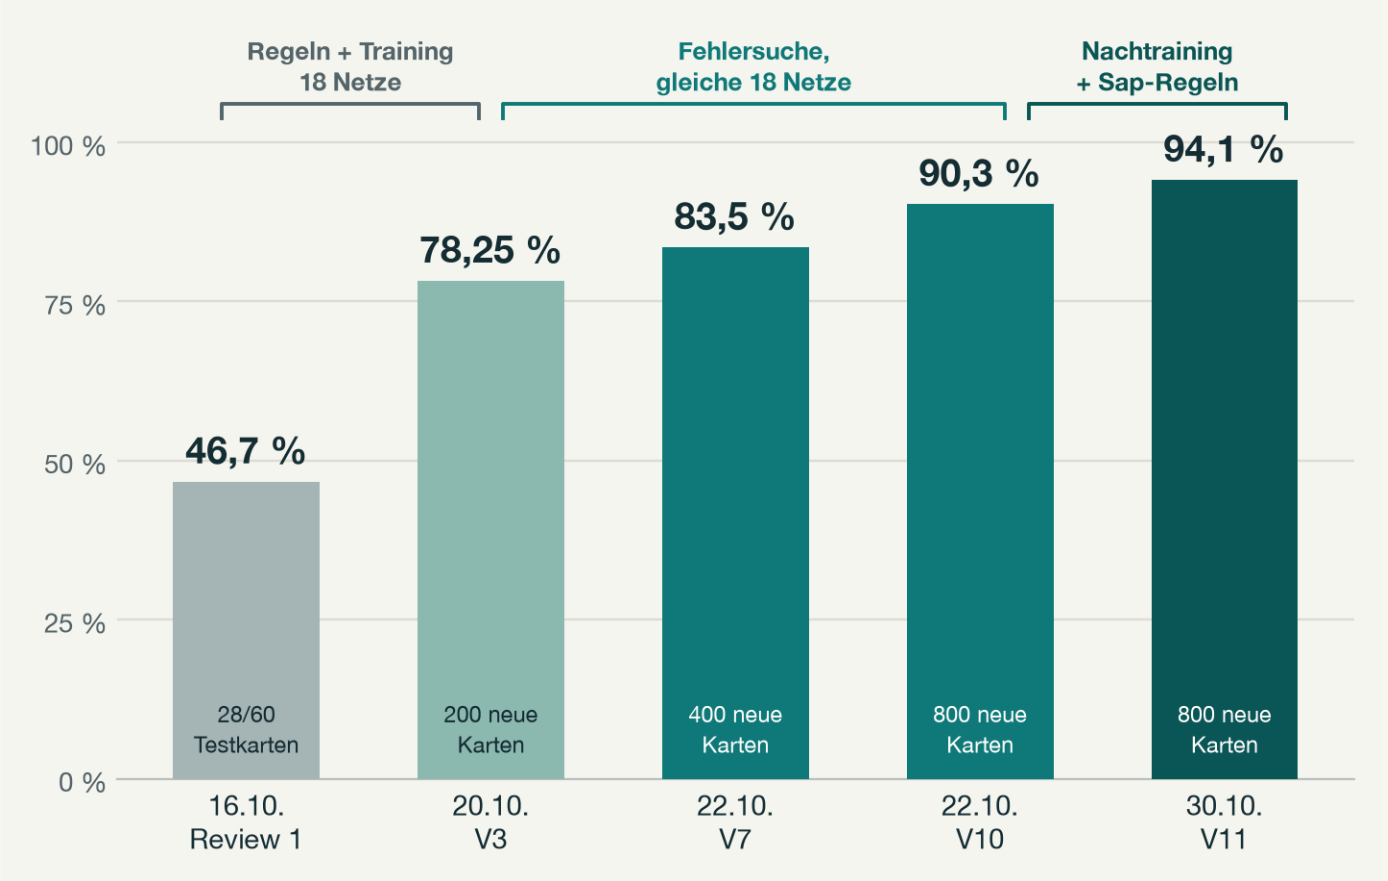
der Entscheidungen spielt Sherlock genau so, wie die Netze sie getroffen haben

Eine einfache Regel statt der Netze gewann am 19.10. nur 3 % gegen Solution_92, mit Netzen 38 %.

Regel greift ein	Anteil
Nur Erkundungsziel: direkt hinlaufen statt warten	4,7 %
Schädlichen Nebel umgehen	1,0 %
Kein Schuss auf ein schon sicher getroffenes Ziel	0,8 %
Sackgasse: kürzesten Weg nehmen	0,7 %
Auf dem Punktefeld stehen und schießen	0,5 %
In eine Gruppe schießen (bei vollem Streuschaden schon ab 2 Treffern)	0,35 %

Anteile an 36.209 Entscheidungen in 10 Spielen gegen Solution_92. Zusammen ändern die Regeln 7,5 % der Aktionen.

Von 47 % auf 94 % gegen Solution_92



BIS 78 %: TRAINING UND REGELN

Neu trainiert mit aktiven Regeln, 18 statt 6 Netze

78 → 90 %: FEHLERSUCHE

Verlorene Spiele mit dem wahren Zustand verglichen: veraltete Karte, Sackgassen, Mehrfachschüsse. Gleiche 18 Netze.

90 → 94 %: NACHTRAINING + SAP-REGELN

Die 18 Netze unter den heutigen Regeln weitertrainiert und mit den alten gemischt. Bei vollem Streuschaden schießt Sherlock aggressiver.

Siegquote gegen Solution_92 auf neuen Karten, beide Seiten; V10 und V11 je auf 800 Karten.

Neu seit letzter Woche: V11

1 · Nachtrainieren und mischen

- Die 18 Netze stammen vom 20.10. und kannten die späteren Regeln nicht
- 18 Kopien je 5.500 Spiele weitertrainiert, alle heutigen Regeln aktiv
- Alte und neue Netze gemischt (36) sind besser als jede Hälfte allein

2 · Verlorene Spiele nach verdeckten Werten sortiert

Streuschaden beim Sap	V10	V11
25 % auf Nachbarfelder	91,4 %	94,5 %
50 %	91,0 %	95,4 %
100 %	86,7 %	92,5 %

Sherlock schätzt den Wert aus eigenen Energieverlusten. Ist er sicher 100 %, schießt Sherlock schon ab 2 Treffern und auch auf ziehende Gegner.

Ergebnis auf 1.600 neuen Spielen je Gegner: Solution_92 **94,1 statt 89,6 %**, unsere Abgabe vom 16.10. 92,9 statt 86,1 %, direkt gegen V10 59,5 % → als V11 übernommen. Tabelle: gegen Solution_92, dieselben 800 Karten. **Danach geprüft:** dieselbe Regel auch bei sicher 50 % Streuschaden. Auf diesen Karten +2,8 Punkte, im Mittel über 6 Gegner aber nur +0,95 statt der verlangten +1,0 → V11 bleibt.

Erkenntnisse

01 Das Gelernte trägt

92 % der Aktionen kommen unverändert aus den Netzen. Eine einfache Regel statt der Netze gewann nur **3 %** statt 38 %.

02 Erst Fehler suchen, dann passend trainieren

Fehler im Agenten finden brachte **78 → 90 %**. Danach half Training wieder, aber erst unter den heutigen Regeln: **90 → 94 %**.

03 Jede Idee auf neuen Karten prüfen

Hürden vorab festlegen und einhalten, auch wenn es knapp wird. Zwei Kandidaten lagen auf 1.600 neuen Spielen je Gegner knapp darunter: +1,8 statt +2 und +0,95 statt +1,0 Punkte. Beide nicht übernommen.

Fazit und Battle

Gelernt entscheiden, programmiert absichern

Im Replay achten auf:

- Einheiten verteilen sich auf verschiedene Ziele
- Einheiten auf Punktefeldern bleiben stehen und schießen, bei vollem Streuschaden auch auf ziehende Gegner
- Schädlicher Nebel wird umgangen

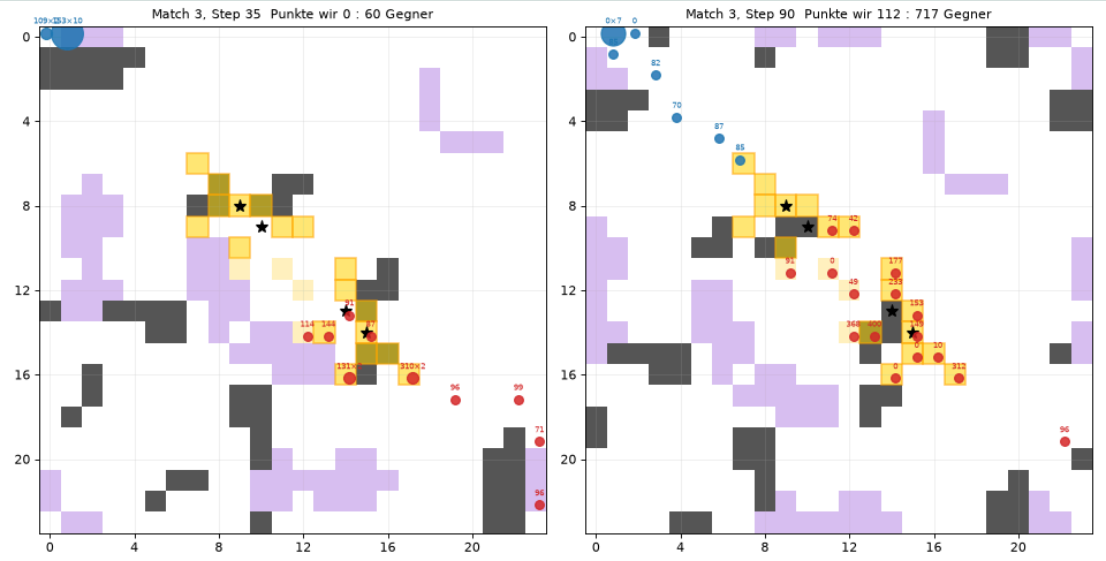
Fragen?

Reserve: So prüfen wir

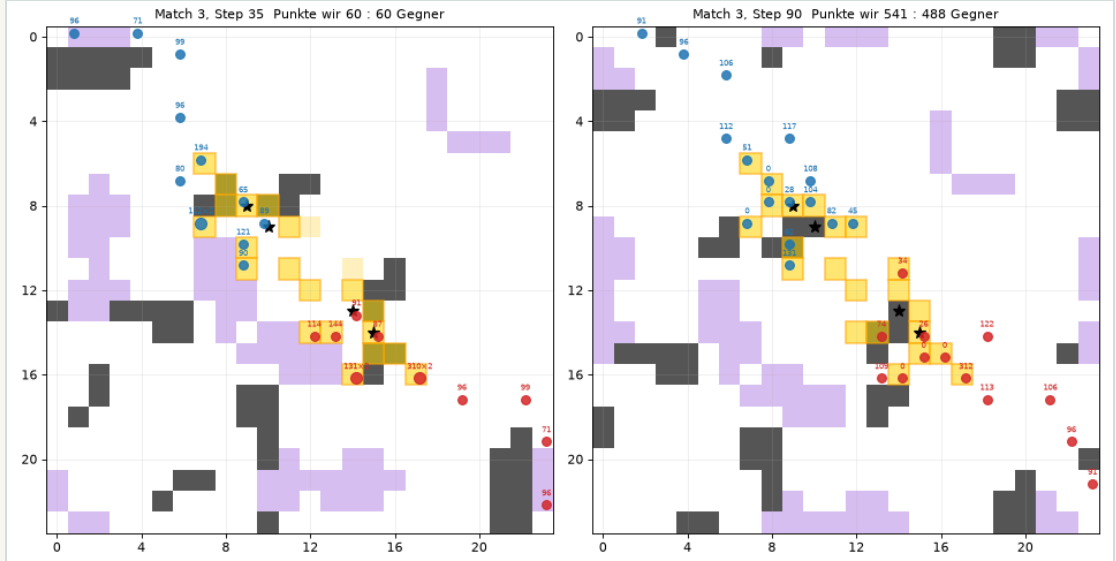
- **Entwicklung:** 300 Karten, beide Seiten, gegen 6 Gegner, darunter 2 RL-Gegner, gegen die nie trainiert wurde. Eine neue Regel zusätzlich auf einem zweiten, unberührten Kartensatz.
- **Auswahl:** 200 neue Karten je Kandidat, höchstens einer kommt weiter.
- **Übernahme nur, wenn alle Hürden auf 800 frischen Karten erfüllt sind** (vorab festgelegt): Mittel über 4 Gegner mindestens +2 Punkte mit 95 %-Untergrenze über 0; gegen Solution_92 nicht schlechter; default mindestens 99 %; direkt gegen die Abgabe mit Untergrenze über 50 %. Letzte Prüfung (31.10.) fürs Battle: Mittel über dieselben 6 Gegner wie in der Entwicklung, mindestens +1 Punkt.
- **Statistik:** gepaarter Bootstrap über ganze Karten (beide Seiten zusammen). **Frische Karten:** jeder Block nur einmal benutzt; alte Abgabe vor jeder Übernahme mit Prüfsumme gesichert.

Reserve: Fehler 1: Die Karte im Gedächtnis war veraltet

Sherlock · Solution_92 · Punktefeld · Asteroid · Nebel · ★ Relic · Zahl = Energie · Karte 360014, Match 3



Vorher: Einheiten am Start eingesperrt · Schritt 90: 112 : 717



Nachher: Einheiten verlassen sofort den Start · Schritt 90: 541 : 488

- Asteroiden und Nebel wandern, Nebel ist bei kleiner Sicht unsichtbar → **18 % der gemerkten Felder waren falsch**
- Lösung: Drift erkennen und Karte mitrollen; unsichtbar trotz Sichtweite heißt Nebel → 210 von 210 Drifts erkannt

Reserve: Spielregeln, die wir nutzen

Sap (Schuss)	im ganzen Quadrat bis zur Reichweite (3–7); Ziel verliert die Schusskosten, Nachbarfelder einen Anteil (Streufaktor 0,25 / 0,5 / 1, verdeckt)
Kollision	Stehen Einheiten beider Teams auf einem Feld, überlebt nur das Team mit mehr Gesamtenergie; bei Gleichstand sterben beide
Energie-Sog	Benachbarte Gegner ziehen Energie ab (Faktor verdeckt, 1/16 bis 3/8)
Drift	Asteroiden und Nebel verschieben sich alle 7–40 Schritte diagonal
Relics	bis zu drei Paare; ein neues Paar kann in Match 2 und 3 in den ersten 50 Schritten erscheinen