# Sherlock

## Wie unser Agent entscheidet und wie wir ihn trainiert haben

36 gelernte Netze, Gedächtnis und Regeln.
95,4 % Siege gegen Solution_92 in 1.600 Testspielen

Mahmoud El-Hassan · Moayed Shawesh
HTW Berlin · Anwendungen der KI · 06.11.2026

# Agenda

1. Was Sherlock bekommt und zurückgibt
2. Ein Spielschritt: Gedächtnis, Netze, Maske, Regeln
3. Training der Netze
4. Von 47 % auf 95 %
5. Neu seit letzter Woche
6. Erkenntnisse und Battle

# Was Sherlock bekommt und zurückgibt

### Eingang in jedem Schritt

- Sichtbare Einheiten beider Teams: Position, Energie
- Sichtbare Felder: Energie, Nebel, Asteroid
- Sichtbare Relics
- Punkte im Match, gewonnene Matches, Schrittzähler
- **Unsichtbar: welche Felder Punkte bringen**

→

## Sherlock

im damaligen Test:
meist 5 ms,
maximal 12 ms

→

### Ausgang

16 × 3 Zahlen, je Einheit
**[Aktion, dx, dy]**

| | |
|---|---|
| **0** | stehen |
| **1–4** | hoch, rechts, runter, links |
| **5** | Sap (Schuss) auf Feld (dx, dy) |

Einmal pro Spiel kommen Zugkosten, Sap-Kosten, Sap-Reichweite und Sichtweite dazu. Verdeckte Werte wie den Energieabzug im Nebel oder den Streuschaden beim Sap schätzt Sherlock aus den Energieverläufen der eigenen Einheiten.

# Ein Spielschritt: wer macht was?

**1**
**Gedächtnis**
Karte, Relics und Punktefelder über alle 3 Matches
PROGRAMMIERT

→

**2**
**Ziele**
Punktefelder, Kandidaten oder Erkundung; nach Weglänge verteilt
PROGRAMMIERT

→

**3**
**Vorbereitung**
79 Merkmale, Aktionsmaske und sichtbares Schussziel berechnen
PROGRAMMIERT

→

**4**
**36 Netze**
bewerten die 6 Aktionen mit Q-Werten, wir mitteln
GELERNT (DQN)

→

**5**
**Auswahl**
Maske anwenden, Aktion mit höchstem verbleibendem Q-Wert wählen
PROGRAMMIERT

→

**6**
**Regeln**
Aktion ändern, Schuss auslösen oder überflüssigen Schuss verhindern
PROGRAMMIERT

→ **16 × 3 Zahlen ans Spiel.** Die Netze bewerten, die Maske begrenzt die Auswahl. **Regeln können danach eingreifen.** Schussziele werden programmiert bestimmt: sichtbare Ziele nach Gegnerenergie und Streuwirkung, verdeckte über eine eigene Regel.

# Gedächtnis: Welche Felder bringen Punkte?

**Beispiel für einen Schritt**

| | |
|---|---|
| Punktezuwachs in diesem Schritt | **3** |
| besetzte Felder | **4** |
| davon schon bewiesene Punktefelder | **2** |

**Also:** von den 2 übrigen Feldern bringt genau 1 einen Punkt

- Solche Gleichungen werden gesammelt, bis sie eindeutig sind
- Die Karte ist spiegelsymmetrisch: ein bewiesenes Feld gilt auch für sein Spiegelfeld
- Asteroiden und Nebel wandern: das Gedächtnis erkennt die Drift und verschiebt die Karte mit
- Relic- und Punktewissen bleibt über 3 Matches erhalten; Erkundung startet pro Match neu

Die Punktefelder sieht kein Agent direkt. Das Spiel zeigt nur, wie viele Punkte das Team im Schritt bekommen hat.

# Action Masking

| Aktion | in der Netzauswahl, wenn … |
|---|---|
| **Stehen** | immer |
| **Zug** | genug Energie, Zielfeld auf der Karte, kein Asteroid |
| **Sicherer Zug** | zusätzlich keine erkennbare Kollision mit einem mindestens gleich starken Gegner |
| **Sap** | sichtbares Schussziel in Reichweite und genug Energie |

- Ausgeblendet heißt: Q-Wert = −∞, in der Netzauswahl ausgeschlossen
- Training: Masken auch für Zufallszüge und Lernziel

**Echtes Beispiel: Einheit vor einem Asteroiden**

| | | |
|---|---|---|
| stehen | 51,0 | |
| hoch | 51,3 | |
| **rechts** | **52,2** | **✓ gespielt** |
| runter | ~~53,8~~ | ✗ Asteroid |
| links | ~~51,2~~ | ✗ Kartenrand |
| Sap | ~~47,6~~ | ✗ kein Gegner |

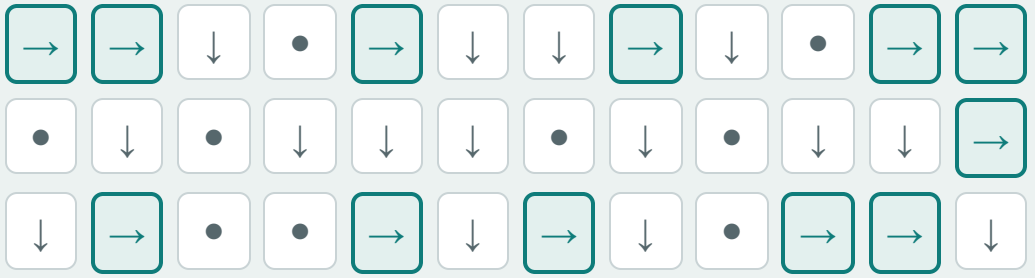
Mittel der 36 Netze. Am liebsten „runter“, das ist aber verboten.

**Danach kann eine Regel einen Blindschuss auslösen:** Sie prüft ein verdecktes Ziel, Reichweite und Energiereserve separat. Die Maske enthält Spielgrenzen und programmierte Sicherheitsregeln.

# 36 Netze entscheiden gemeinsam

- **Keine Aufteilung auf Spiele:** alle 36 Netze bewerten jede Einheit in jedem Schritt
- Gleiche Bauart: 79 → 256 → 256 → 6 Q-Werte (Dueling-DQN, 153.000 Parameter je Netz)
- Ein Netz für alle Einheiten und beide Seiten: die Karte wird für Spieler 2 gespiegelt
- Q-Werte je Aktion mitteln → beste erlaubte Aktion
- **Warum 36?** 18 Netze vom 20.10. und dieselben 18 nachtrainiert. Gemischt besser als jede Hälfte allein.

**Echtes Beispiel: die 36 Netze sind uneinig**



→ rechts **12** ↓ runter **15** • stehen **9**

Mehrheit wäre **runter**. Der Mittelwert wählt **rechts** (27,0 vor 26,9): Es zählt die **Höhe der Aktionswerte**, keine Wahrscheinlichkeit.

V11-Diagnose, 10 Spiele / 36.209 Entscheidungen: alle Netze einig in 31 %; im Mittel wählen 27,4 von 36 Netzen dieselbe Aktion wie das Ensemble. Mittelwert und Mehrheitswahl unterscheiden sich in 6 %.

# So wurden die 36 Netze trainiert

| Gruppe | Netze | Spiele je Netz | Gegner nach 25 % Aufwärmen gegen default |
|---|---|---|---|
| **A** | 6 | 3.000 | abwechselnd default und Solution_92 |
| **B** | 6 | 4.000 | 70 % Solution_92, Rest default |
| **C** | 6 | 4.000 | 60 % Solution_92, 20 % eigene alte Agenten; Strafe für Gegnerpunkte |
| **Nach-training** | 18 Kopien | + 5.500 | damalige V10-Regeln aktiv; 70 % Solution_92 und zwei Varianten, 20 % eigene Abgaben, Rest default und Rush-Bot |

- **66.000 + 99.000 Trainingsspiele** für die Netzfamilien der Abgabe; weitere Projektversuche separat
- Double DQN mit Target-Netz und Replay Buffer (300.000 Übergänge)
- Reward pro Schritt: Punktefeld halten, Annäherung, Erkunden; Abzug bei Tod. **Matchbonus am Matchende.**
- Endstände der Läufe; V11–V14 nutzen dieselben 36 Netze mit späteren Regeländerungen

# Netze und Regeln

**91 %**

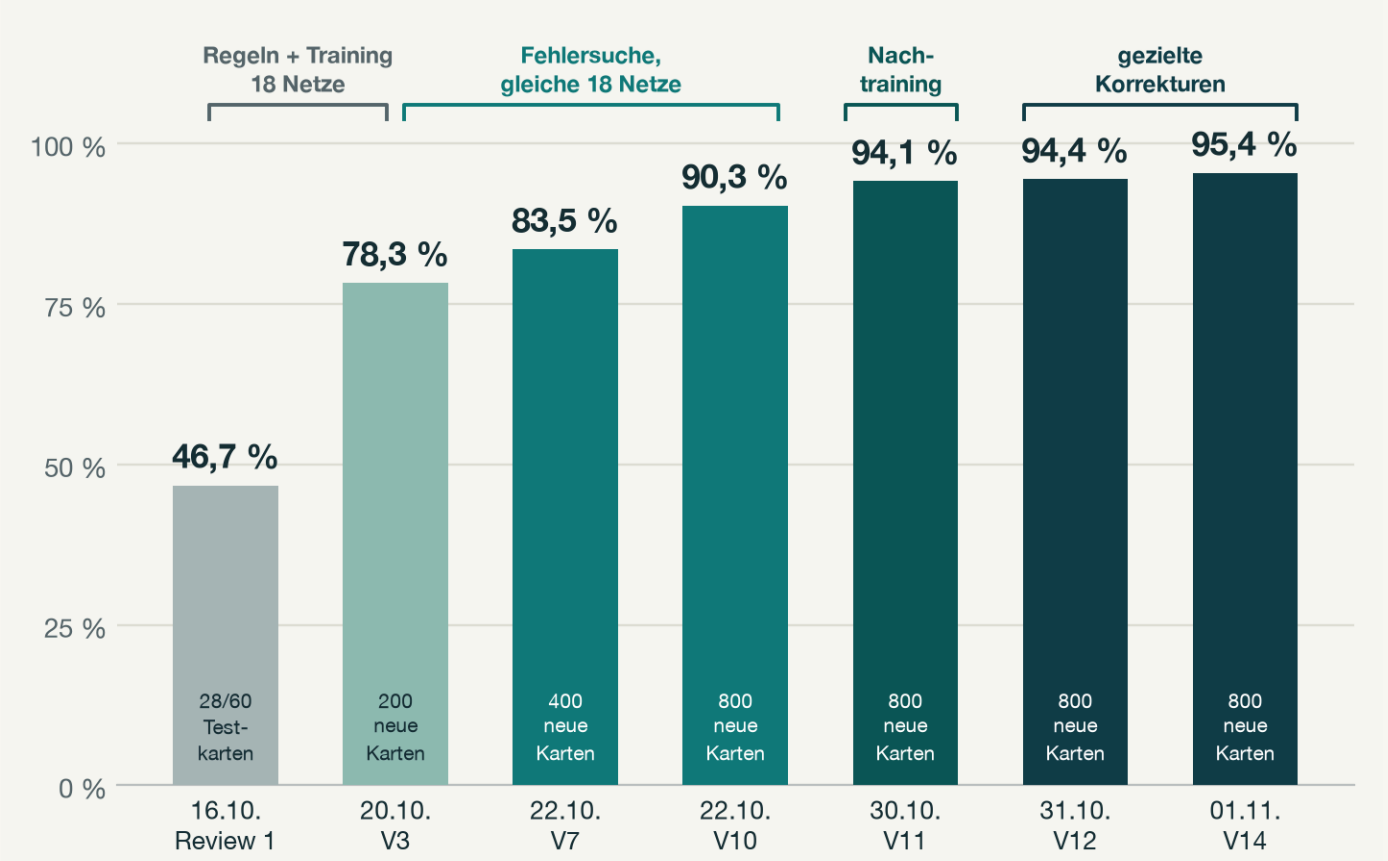
ohne protokollierten Regeleingriff nach der **maskierten Netzauswahl** in einer V12-Diagnose

Ziele, Merkmale und Maske sind bereits programmiert. 91 % bedeutet daher nicht „ohne Regeln“.

| Regel greift ein | Anteil |
|---|---|
| Nur Erkundungsziel: direkt hinlaufen statt warten | 4,6 % |
| Auf dem Punktefeld stehen und schießen | 1,3 % |
| Schädlichen Nebel umgehen | 1,1 % |
| Überflüssigen Schuss durch Stehen ersetzen | 1,1 % |
| Sackgasse: kürzesten Weg nehmen | 0,7 % |
| In eine Gruppe schießen (bei sicher hohem Streuschaden schon ab 2 Treffern) | 0,6 % |

Historische Diagnose: 36.204 Entscheidungen in 10 V12-Spielen gegen Solution_92. Regeln ändern 8,3 % der Aktionen; Blindschüsse hier nur 0,1 % (Sichtweite 2–4). Keine allgemeine V14-Quote.

# Von 47 % auf 95 % gegen Solution_92




**BIS 78 %: TRAINING UND REGELN**

Neu trainiert mit aktiven Regeln, 18 statt 6 Netze

**78 → 90 %: FEHLERSUCHE**

Verlorene Spiele mit dem wahren Zustand verglichen. Gleiche 18 Netze.

**90 → 94 %: NACHTRAINING**

18 Netze unter V10-Regeln nachtrainiert, alt + neu gemischt; neue Schussregeln

**94 → 95 %: GEZIELTE KORREKTUREN**

Unsichtbare Gegner treffen, Nebel richtig einschätzen, Kandidaten-Rettung

Historische Tests auf verschiedenen Kartensätzen, beide Seiten; ab V10 je 800 Karten. Kein isolierter Wirkungsnachweis einzelner Änderungen. V13 nur auf starkem Nebel geprüft, daher ohne Balken.

# Neue Versionen

| Version | Was neu ist | Solution_92 | Mittel 6 Gegner |
|---|---|---|---|
| **V11 · 30.10.** | **Nachtraining unter V10-Regeln:** alte + nachtrainierte Netze (36), ergänzt um Schussregeln | **89,6 → 94,1 %** | **nicht gemessen** |
| **V12 · 31.10.** | **Blindschüsse:** Gegner punktet verdeckt → vermutetes Punktefeld beschießen | **93,0 → 94,4 %** | **81,2 → 87,1 %** |
| **V13 · 01.11.** | **Nebelkosten:** Energie 0 bedeutet nicht „Nebel kostenlos“ | **94,2 → 95,0 %[1]** | **84,8 → 87,2 %[1]** |
| **V14 · 01.11.** | **Kandidaten-Rettung:** nach 30 Schritten ohne Punktefund gezielt Relic-Umgebung testen | **94,9 → 95,4 %** | **86,7 → 87,6 %** |

Je Zeile eigener Vergleich mit der Vorgängerversion: 800 neue Karten / 1.600 Spiele je Gegner; [1] V13 auf 300 Karten mit starkem Nebel. V14 wurde trotz zweier verfehlter Übernahmehürden per dokumentierter Teamentscheidung übernommen.

# Erkenntnisse

## 01 Netze und Regeln ergänzen sich

Die Netze bewerten Aktionen. Gedächtnis, Zielzuweisung und Regeln unterstützen die Auswahl. Gezielte Fehlerkorrekturen brachten große Fortschritte.

## 02 Neue Karten entscheiden

Eine neue Regel brachte im Entwicklungstest **+1,8 Prozentpunkte**, auf 800 neuen Karten aber **–0,35**. Deshalb wurde sie nicht übernommen.

## 03 Mehr ist nicht automatisch besser

02.–04.11.: kleinere und größere Ensembles, Einzelnetz-Schüler und Nachtraining mit Lehrerbeispielen geprüft. **Kein ausreichend belegter Ersatz – V14 bleibt.**

# Fazit und Battle

## Gelernt entscheiden, programmiert absichern

Im Replay achten auf:

- Einheiten verteilen sich auf verschiedene Ziele
- Einheiten auf Punktefeldern bleiben stehen und schießen
- Bei kleiner Sicht schießen sie auch auf Gegner, die sie nicht sehen
- Schädlicher Nebel wird umgangen
- Findet Sherlock lange kein Punktefeld, testen die Einheiten die Felder um das Relic

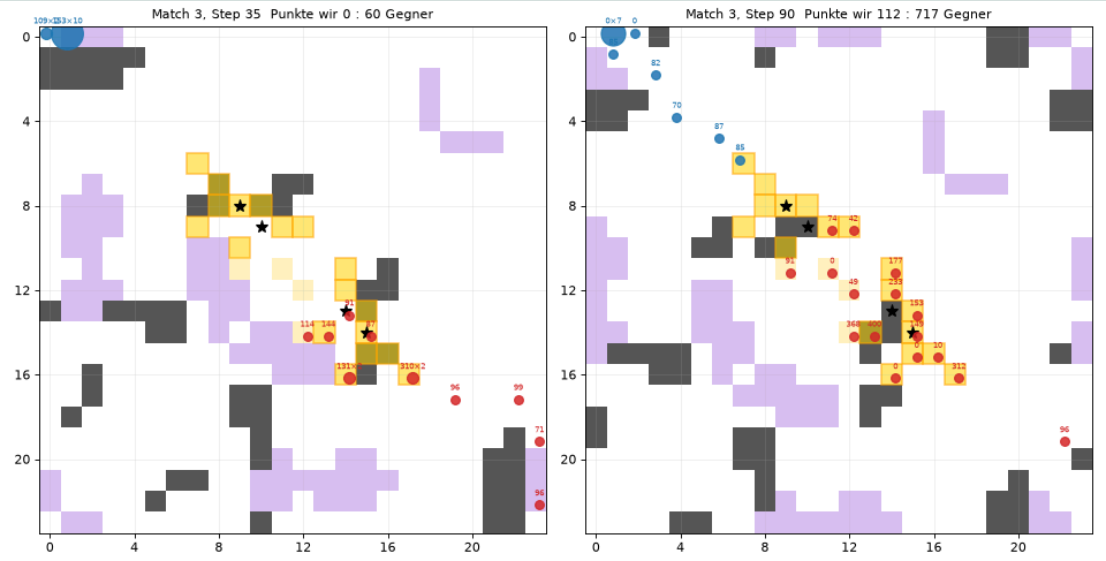
## Fragen?

# Reserve: So prüfen wir

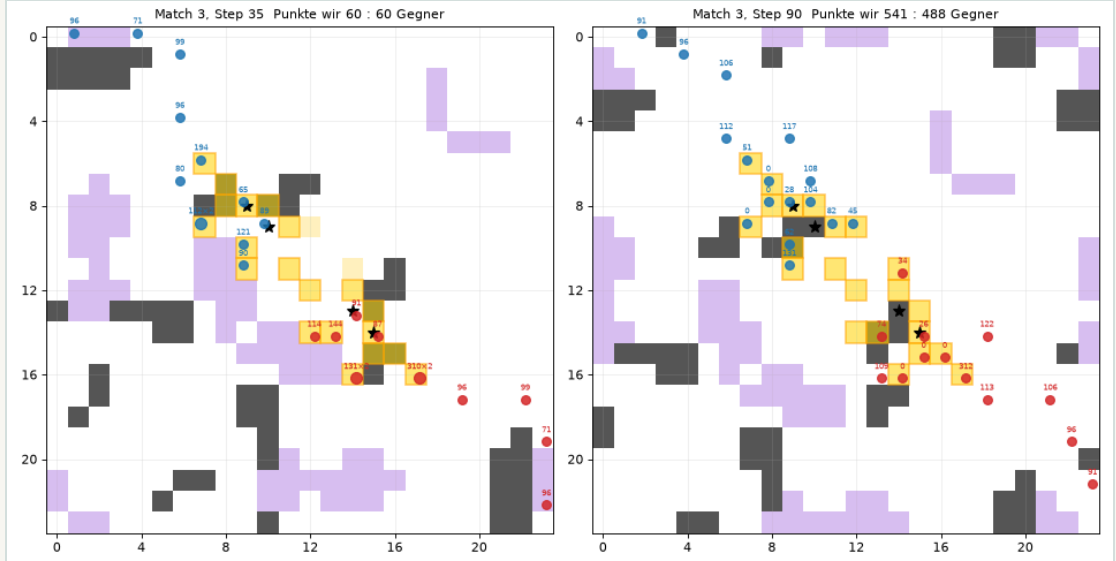
- **Entwicklung:** 300 Karten, beide Seiten, gegen 6 Gegner, darunter 2 RL-Gegner, gegen die nie trainiert wurde. Was auf diesen Karten entwickelt und ausgewählt wurde, sieht dort zu gut aus; entscheidend sind neue Karten.
- **Auswahl:** 200 neue Karten je Kandidat, höchstens einer kommt weiter.
- **Vorab festgelegte Hürden:** frische Karten, Panelgewinn mit positiver 95-%-Untergrenze, begrenzte Verluste gegen Solution_92/default und Direktduell-Untergrenze über 50 %. Im Battle-Protokoll: mindestens +1 Prozentpunkt im Mittel über 6 Gegner. Umfang und genaue Grenzen stehen jeweils vor dem Vergleich fest.
- **V14 war eine dokumentierte Ausnahme:** Panel +0,86 statt mindestens +1 Prozentpunkt (Intervall +0,48 bis +1,28); Direktduell 50,6 % mit Untergrenze 49,25 statt über 50 %. **Zwei Hürden verfehlt**, Übernahme per Teamentscheidung. Spätere Kandidaten wurden nicht übernommen.
- **Statistik:** gepaarter Bootstrap über ganze Karten (beide Seiten zusammen). **Frische Karten:** jeder Block nur einmal benutzt; alte Abgabe vor jeder Übernahme mit Prüfsumme gesichert.

# Reserve: Fehler 1: Die Karte im Gedächtnis war veraltet

Sherlock · Solution_92 · Punktefeld · Asteroid · Nebel · ★ Relic · Zahl = Energie · Karte 360014, Match 3




**Vorher:** Einheiten am Start eingesperrt · Schritt 90: 112 : 717




**Nachher:** Einheiten verlassen sofort den Start · Schritt 90: 541 : 488

- Asteroiden und Nebel wandern, Nebel ist bei kleiner Sicht unsichtbar → **18 % der gemerkten Felder waren falsch**
- Lösung: Drift erkennen und Karte mitrollen; unsichtbar trotz Sichtweite heißt Nebel → 210 von 210 Drifts erkannt

# Reserve: Spielregeln, die wir nutzen

| | |
|---|---|
| **Sap (Schuss)** | im ganzen Quadrat bis zur Reichweite (3–7); Ziel verliert die Schusskosten, Nachbarfelder einen Anteil (Streufaktor 0,25 / 0,5 / 1, verdeckt) |
| **Kollision** | Stehen Einheiten beider Teams auf einem Feld, überlebt nur das Team mit mehr Gesamtenergie; bei Gleichstand sterben beide |
| **Energie-Sog** | Benachbarte Gegner ziehen Energie ab (Faktor verdeckt, 1/16 bis 3/8) |
| **Drift** | Asteroiden und Nebel verschieben sich alle 7–40 Schritte diagonal |
| **Relics** | bis zu drei Paare; ein neues Paar kann in Match 2 und 3 in den ersten 50 Schritten erscheinen |
| **Lage der Relics** | auf den höchsten Werten eines Zufallsrauschens mit 6er-Raster: 97 % liegen auf Zeilen oder Spalten mit Rest 2 oder 3 (geteilt durch 6); spätere Paare meist direkt neben früheren (10.000 Karten gezählt) |
| **Punktefelder** | je Relic 5 × 5 Felder, jedes mit 20 % Wahrscheinlichkeit; liegt ein Feld bei zwei Relics, 34 % |

# Reserve: Wie viel fehlt noch? Der Orakel-Test

- Im Test bekommt Sherlock (V14) in jedem Schritt das **wahre Wissen**, das kein Agent hat: wo Relics liegen und welche Felder Punkte bringen
- Die Diagnose zeigt einen möglichen Informationsengpass, keinen garantierten Gewinn eines einsetzbaren Agenten
- Im Mittel über 6 Gegner: **86,5 → 91,0 %**
- Bei Sichtweite 1 allein die Punktefelder: 94,4 %, allein die Relics: 90,3 %

**Gegen Solution_92 nach Sichtweite**

| Sichtweite | normal | mit Orakel |
|---|---|---|
| **1 Feld** | **85,4 %** | **96,5 %** |
| 2 Felder | 94,2 % | 95,5 % |
| 3 Felder | 98,1 % | 98,7 % |
| 4 Felder | 100 % | 99,3 % |

Nur Diagnose: 300 Entwicklungskarten, beide Seiten, je Gegner 600 Spiele. Das Zusatzwissen ist im normalen Spiel nicht verfügbar. Die untersuchten Karten zeigen besonders bei Sichtweite 1 Potenzial durch bessere Information.