# Sherlock

## Gedächtnis · 36 Netze · koordinierte Aktionen

Wie aus einer Beobachtung
eine Aktion für jede Einheit wird

Mahmoud El-Hassan · Moayed Shawesh
HTW Berlin · Anwendungen der KI · 06.11.2026

# Entscheidungsablauf

**1**
### Gedächtnis
Karte, Relics und Punktefelder über alle 3 Matches

PROGRAMMIERT

→

**2**
### Ziele
Punktefelder, Kandidaten oder Erkundung; nach Weglänge verteilt

PROGRAMMIERT

→

**3**
### Vorbereitung
79 Zahlen je Einheit, Maske und sichtbares Schussziel vorbereiten

PROGRAMMIERT

→

**4**
### 36 Netze
bewerten die 6 Aktionen mit Q-Werten, wir mitteln

GELERNT (DQN)

→

**5**
### Auswahl
Maske anwenden, Aktion mit höchstem verbleibendem Q-Wert wählen

PROGRAMMIERT

→

**6**
### Regeln
Aktion ändern, Schuss auslösen oder überflüssigen Schuss verhindern

PROGRAMMIERT

**Eingang:** sichtbare Einheiten, Karte und Punktestand. **Ausgang:** bis zu 16 × [Aktion, dx, dy].
Die Maske begrenzt die Netzauswahl. **Regeln können die gewählte Aktion danach ändern.**

# Gedächtnis und Ziele

### Punktefelder erschließen

| | |
|---|---|
| Punktezuwachs | 3 |
| Besetzte Felder | 4 |
| Davon als Punktefeld bekannt | 2 |

Also bringt **genau eines der zwei übrigen Felder** einen Punkt.

Sherlock sammelt solche Gleichungen, nutzt die Spiegelsymmetrie und führt die bewegliche Karte mit.

### Ziele werden programmiert zugewiesen

1. **Punkte besetzen**
   Bekannte, geeignete Punktefelder
2. **Kandidaten testen**
   Mögliche Punktefelder um Relics
3. **Weiter erkunden**
   Unbekannte Bereiche absuchen

**Grundpriorität:** Weglänge und Erreichbarkeit zählen mit. Nahe eigene Kandidaten können vor fernen gegnerischen Punkten liegen.

**Das zugewiesene Ziel geht als Merkmal ins Netz.** Relic- und Punktewissen bleibt über drei Matches erhalten; Erkundung startet pro Match neu. Ein neues Spiel beginnt mit neuem Gedächtnis.

# Die 79 Merkmale

**Ein Merkmal = eine Zahl.** Für jede Einheit entsteht in jedem Schritt ein neuer Vektor.

| Gruppe | Anzahl | Beispiele |
|---|---|---|
| Eigene Lage und Spielparameter | **10** | Position, Energie, Zugkosten, Sichtweite |
| Punktestand | **4** | Eigene Punkte, Punktedifferenz, Matchsiege |
| **Ziele** | **20** | **Richtung und Abstand zum zugewiesenen Ziel** und zu vier Zielarten |
| Aktuelles Feld | **5** | Punktefeld? Kandidat? Nebel? Eigene Einheiten? |
| Eigenes Feld und vier Nachbarn | **30** | Begehbarkeit, Feldenergie, Punktewissen, Besetzung |
| Gegner | **6** | Richtung, Abstand, Energie und sichtbare Gegnerzahl |
| Globale Zähler | **4** | Eigene Einheiten, bekannte Punktefelder, erkundeter Anteil |

**Beispiel:** 200 von 400 Energie → Merkmal 0,5. Dieselben 79 Zahlen einer Einheit gehen an alle 36 Netze. Die Aktionsmaske ist separat; die Netzgewichte bleiben im Spiel fest.

# Das Ensemble

### Gleiche Bauart, unterschiedliche Gewichte

- **79 → 256 → 256 → 6 Q-Werte**
  Dueling-DQN, rund 153.000 Parameter je Netz
- **18 Grundnetze:** unterschiedliche Zufallsstarts, Trainingskarten, Gegner- und Reward-Konfigurationen
- **18 Nachtrainingspartner:** aus diesen Netzen, jeweils 5.500 zusätzliche Spiele
- **36 verschiedene Gewichtsstände.** Alle bewerten jede Einheit; es gibt keine feste Rollenverteilung.

### Reales Beispiel: Mittelwert statt Abstimmung

| Aktion | Erste Wahl | Q-Mittel |
|---|---|---|
| Stehen | 9 Netze | 26,561 |
| **Rechts ✓** | **12 Netze** | **26,990** |
| Runter | 15 Netze | 26,948 |

„Runter“ hat die meisten Erstwahlen.
**Im Q-Mittel gewinnt „rechts“.**

Q-Werte schätzen künftigen Reward, keine Wahrscheinlichkeiten.

**Nutzen:** Das Mittel kann einzelne Fehlbewertungen abschwächen. Gemeinsame Fehler bleiben möglich.

Nachtrainingspartner sind verwandt, keine 36 unabhängigen Neustarts. Beispiel aus V11 mit denselben Netzen.

# Training und Reward

## Lernen vor dem Battle

### 1 · Spielen und sammeln

Situation, Aktion, Reward und Folgesituation pro Einheit → Replay Buffer

### 2 · Bewertungen verbessern

Double DQN lernt aus zufälligen Mini-Batches; Target-Netz für das Lernziel

### 3 · Gewichte fixieren

18 Grundnetze + 18 nachtrainierte Stände bilden das Ensemble

## Reward pro Einheit – Auszug

| Situation | Signal |
|---|---|
| Punktefeld als Halter sichern | **positiv** |
| Änderung der Zielnähe | Potential-Shaping[1] |
| Neue Felder oder Punkte entdecken | **positiv** |
| Einheit verloren | negativ |
| Matchende | Bonus / Abzug |

**Battle: Gewichte fest, Gedächtnis veränderlich.**

66.000 Grundtrainingsspiele + 99.000 Nachtrainingsspiele unter V10-Regeln; weitere Versuche separat.
Reward pro Schritt, Matchbonus erst am Ende. [1] Signal aus diskontierter Veränderung des Zielpotentials: $\gamma\Phi(s') - \Phi(s)$.

# Action Masking

| Aktion | in der Netzauswahl, wenn … |
|---|---|
| **Stehen** | immer |
| **Zug** | genug Energie, Zielfeld auf der Karte, kein Asteroid |
| **Sicherer Zug** | zusätzlich keine erkennbare Kollision mit einem mindestens gleich starken Gegner |
| **Sap** | sichtbares Schussziel in Reichweite und genug Energie |

- Ausgeblendet heißt: Q-Wert = −∞, in der Netzauswahl ausgeschlossen
- Training: Masken auch für Zufallszüge und Lernziel

**Echtes Beispiel: Einheit vor einem Asteroiden**

| | | |
|---|---|---|
| stehen | 51,0 | |
| hoch | 51,3 | |
| **rechts** | **52,2** | **✓ gespielt** |
| runter | ~~53,8~~ | ✗ Asteroid |
| links | ~~51,2~~ | ✗ Kartenrand |
| Sap | ~~47,6~~ | ✗ kein Gegner |

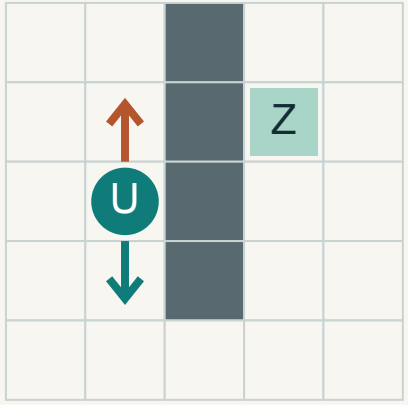
Mittel der 36 Netze. Am liebsten „runter“, das ist aber verboten.

**Danach kann eine Regel einen Blindschuss auslösen:** Sie prüft ein verdecktes Ziel, Reichweite und Energiereserve separat. Die Maske enthält Spielgrenzen und programmierte Sicherheitsregeln.

# Regelkorrekturen

## 1 · Weg zum bestehenden Ziel

Ein Zug verkürzt die direkte Entfernung, aber nicht den begehbaren Weg um Hindernisse.




U = Einheit · Z = zugewiesenes Ziel

**Gewählt: hoch ↑**
Direkt: 3 → 2 Felder
Begehbar: 7 → 8

**Korrektur: runter ↓**
Begehbar: 7 → 6

**Das Ziel bleibt gleich.** Wenn möglich: erlaubter erster Schritt auf dem kürzesten begehbaren Weg.

## 2 · Verdecktes Ziel beschießen

Ein Halter würde stehen. Gegnerpunkte deuten auf verdeckte Besetzung. Passendes Punktefeld in Reichweite und genug Energiereserve?

**Dann: STEHEN → SAP**

Eigene Prüfung; der genaue Aufenthaltsort ist nicht sicher bekannt.

## 3 · Überflüssigen Schuss verhindern

Andere eigene Einheiten haben bereits genug Schaden auf dieses Ziel geplant?

**Dann: SAP → STEHEN**

Kein erneuter Netzentscheid.

Nach der maskierten Netzauswahl; ausgewählte Regeln in Ausführungsreihenfolge. Weitere Sicherheitsprüfungen können folgen.
Karte schematisch; Wege nach aktuellem Kartenwissen. Das Ziel wird vorher zugewiesen.

# Im Battle

## Wissen sammeln → Bewerten → Gemeinsam handeln

- Gedächtnis und Zielzuweisung liefern den Kontext.
- 36 unterschiedliche Netze bewerten mögliche Aktionen.
- Maske und Regeln machen daraus die ausgeführten Aktionen.

Abgegebener V14: 95,4 % Siege gegen Solution_92

Historischer Test: 800 neue Karten × beide Seiten = 1.600 Spiele.

## Fragen?

# Reserve: Trainingsdetails

| Gruppe | Netze | Spiele je Netz | Gegner nach 25 % Aufwärmen gegen default |
|---|---|---|---|
| **A** | 6 | 3.000 | abwechselnd default und Solution_92 |
| **B** | 6 | 4.000 | 70 % Solution_92, Rest default |
| **C** | 6 | 4.000 | 60 % Solution_92, 20 % eigene alte Agenten; Strafe für Gegnerpunkte |
| **Nach-training** | 18 Kopien | + 5.500 | damalige V10-Regeln aktiv; 70 % Solution_92 und zwei Varianten, 20 % eigene Abgaben, Rest default und Rush-Bot |

- **66.000 + 99.000 Trainingsspiele** für die Netzfamilien der Abgabe; weitere Projektversuche separat
- Dueling: 79 → 256 → 256; Wert-Kopf 128 → 1 und Vorteil-Kopf 128 → 6
- Reward pro Schritt: Punktefeld halten, Annäherung, Erkunden; Abzug bei Tod. **Matchbonus am Matchende.**
- Double DQN, Replay Buffer mit 300.000 Übergängen; Q = V + A – Mittelwert(A)

# Reserve: So prüfen wir

- **Entwicklung:** 300 Karten, beide Seiten, gegen 6 Gegner, darunter 2 RL-Gegner, gegen die nie trainiert wurde. Was auf diesen Karten entwickelt und ausgewählt wurde, sieht dort zu gut aus; entscheidend sind neue Karten.
- **Auswahl:** 200 neue Karten je Kandidat, höchstens einer kommt weiter.
- **Vorab festgelegte Hürden:** frische Karten, Panelgewinn mit positiver 95-%-Untergrenze, begrenzte Verluste gegen Solution_92/default und Direktduell-Untergrenze über 50 %. Im Battle-Protokoll: mindestens +1 Prozentpunkt im Mittel über 6 Gegner. Umfang und genaue Grenzen stehen jeweils vor dem Vergleich fest.
- **V14 war eine dokumentierte Ausnahme:** Panel +0,86 statt mindestens +1 Prozentpunkt (Intervall +0,48 bis +1,28); Direktduell 50,6 % mit Untergrenze 49,25 statt über 50 %. **Zwei Hürden verfehlt**, Übernahme per Teamentscheidung. Spätere Kandidaten wurden nicht übernommen.
- **Statistik:** gepaarter Bootstrap über ganze Karten (beide Seiten zusammen). **Frische Karten:** jeder Block nur einmal benutzt; alte Abgabe vor jeder Übernahme mit Prüfsumme gesichert.

# Reserve: Spielregeln, die wir nutzen

| | |
|---|---|
| **Sap (Schuss)** | im ganzen Quadrat bis zur Reichweite (3–7); Ziel verliert die Schusskosten, Nachbarfelder einen Anteil (Streufaktor 0,25 / 0,5 / 1, verdeckt) |
| **Kollision** | Stehen Einheiten beider Teams auf einem Feld, überlebt nur das Team mit mehr Gesamtenergie; bei Gleichstand sterben beide |
| **Energie-Sog** | Benachbarte Gegner ziehen Energie ab (Faktor verdeckt, 1/16 bis 3/8) |
| **Drift** | Asteroiden und Nebel verschieben sich alle 7–40 Schritte diagonal |
| **Relics** | bis zu drei Paare; ein neues Paar kann in Match 2 und 3 in den ersten 50 Schritten erscheinen |
| **Lage der Relics** | auf den höchsten Werten eines Zufallsrauschens mit 6er-Raster: 97 % liegen auf Zeilen oder Spalten mit Rest 2 oder 3 (geteilt durch 6); spätere Paare meist direkt neben früheren (10.000 Karten gezählt) |
| **Punktefelder** | je Relic 5 × 5 Felder, jedes mit 20 % Wahrscheinlichkeit; bei zwei Relics in unserer Kartenmessung ca. 34 % |