Sherlock

Gedächtnis · 36 Netze · koordinierte Aktionen

Wie aus einer Beobachtung
eine Aktion für jede Einheit wird

Mahmoud El-Hassan · Moayed Shawesh
HTW Berlin · Anwendungen der KI · 06.11.2026

Entscheidungsablauf

1
Gedächtnis
Karte, Relics und Punktefelder über alle 3 Matches

PROGRAMMIERT

→

2
Ziele
Punktefelder, Kandidaten oder Erkundung; nach Weglänge verteilt

PROGRAMMIERT

→

3
Vorbereitung
79 Zahlen je Einheit, Maske und sichtbares Schussziel vorbereiten

PROGRAMMIERT

→

4
36 Netze
bewerten die 6 Aktionen mit Q-Werten, wir mitteln

GELERNT (DQN)

→

5
Auswahl
Maske anwenden, Aktion mit höchstem verbleibendem Q-Wert wählen

PROGRAMMIERT

→

6
Regeln
Aktion ändern, Schuss auslösen oder überflüssigen Schuss verhindern

PROGRAMMIERT

Eingang: sichtbare Einheiten, Karte und Punktestand. **Ausgang:** bis zu 16 × [Aktion, dx, dy].
Die Maske begrenzt die Netzauswahl. **Regeln können die gewählte Aktion danach ändern.**

Gedächtnis und Ziele

Punktefelder erschließen

Punktezuwachs	3
Besetzte Felder	4
Davon als Punktefeld bekannt	2

Also bringt **genau eines der zwei übrigen Felder** einen Punkt.

Sherlock sammelt solche Gleichungen, nutzt die Spiegelsymmetrie und führt die bewegliche Karte mit.

Ziele werden programmiert zugewiesen

1. **Punkte besetzen**
   Bekannte, geeignete Punktefelder
2. **Kandidaten testen**
   Mögliche Punktefelder um Relics
3. **Weiter erkunden**
   Unbekannte Bereiche absuchen

Grundpriorität: Weglänge und Erreichbarkeit zählen mit. Nahe eigene Kandidaten können vor fernen gegnerischen Punkten liegen.

Das zugewiesene Ziel geht als Merkmal ins Netz. Relic- und Punktewissen bleibt über drei Matches erhalten; Erkundung startet pro Match neu. Ein neues Spiel beginnt mit neuem Gedächtnis.

Die 79 Merkmale

Ein Merkmal = eine Zahl. Für jede Einheit entsteht in jedem Schritt ein neuer Vektor.

Gruppe	Anzahl	Beispiele
Eigene Lage und Spielparameter	**10**	Position, Energie, Zugkosten, Sichtweite
Punktestand	**4**	Eigene Punkte, Punktedifferenz, Matchsiege
Ziele	**20**	**Richtung und Abstand zum zugewiesenen Ziel** und zu vier Zielarten
Aktuelles Feld	**5**	Punktefeld? Kandidat? Nebel? Eigene Einheiten?
Eigenes Feld und vier Nachbarn	**30**	Begehbarkeit, Feldenergie, Punktewissen, Besetzung
Gegner	**6**	Richtung, Abstand, Energie und sichtbare Gegnerzahl
Globale Zähler	**4**	Eigene Einheiten, bekannte Punktefelder, erkundeter Anteil

Beispiel: 200 von 400 Energie → Merkmal 0,5. Dieselben 79 Zahlen einer Einheit gehen an alle 36 Netze. Die Aktionsmaske ist separat; die Netzgewichte bleiben im Spiel fest.

Das Ensemble

Gleiche Bauart, unterschiedliche Gewichte

- **79 → 256 → 256 → 6 Q-Werte**
  Dueling-DQN, rund 153.000 Parameter je Netz
- **18 Grundnetze:** unterschiedliche Zufallsstarts, Trainingskarten, Gegner- und Reward-Konfigurationen
- **18 Nachtrainingspartner:** aus diesen Netzen, jeweils 5.500 zusätzliche Spiele
- **36 verschiedene Gewichtsstände.** Alle bewerten jede Einheit; es gibt keine feste Rollenverteilung.

Reales Beispiel: Mittelwert statt Abstimmung

Aktion	Erste Wahl	Q-Mittel
Stehen	9 Netze	26,561
Rechts ✓	**12 Netze**	**26,990**
Runter	15 Netze	26,948

„Runter“ hat die meisten Erstwahlen.
Im Q-Mittel gewinnt „rechts“.

Q-Werte schätzen künftigen Reward, keine Wahrscheinlichkeiten.

Nutzen: Das Mittel kann einzelne Fehlbewertungen abschwächen. Gemeinsame Fehler bleiben möglich.

Nachtrainingspartner sind verwandt, keine 36 unabhängigen Neustarts. Beispiel aus V11 mit denselben Netzen.

Training und Reward

Lernen vor dem Battle

1 · Spielen und sammeln

Situation, Aktion, Reward und Folgesituation pro Einheit → Replay Buffer

2 · Bewertungen verbessern

Double DQN lernt aus zufälligen Mini-Batches; Target-Netz für das Lernziel

3 · Gewichte fixieren

18 Grundnetze + 18 nachtrainierte Stände bilden das Ensemble

Reward pro Einheit – Auszug

Situation	Signal
Punktefeld als Halter sichern	**positiv**
Änderung der Zielnähe	Potential-Shaping[1]
Neue Felder oder Punkte entdecken	**positiv**
Einheit verloren	negativ
Matchende	Bonus / Abzug

Battle: Gewichte fest, Gedächtnis veränderlich.

66.000 Grundtrainingsspiele + 99.000 Nachtrainingsspiele unter V10-Regeln; weitere Versuche separat.
Reward pro Schritt, Matchbonus erst am Ende. [1] Signal aus diskontierter Veränderung des Zielpotentials: $\gamma\Phi(s') - \Phi(s)$.

Action Masking

Aktion	in der Netzauswahl, wenn …
Stehen	immer
Zug	genug Energie, Zielfeld auf der Karte, kein Asteroid
Sicherer Zug	zusätzlich keine erkennbare Kollision mit einem mindestens gleich starken Gegner
Sap	sichtbares Schussziel in Reichweite und genug Energie

- Ausgeblendet heißt: Q-Wert = −∞, in der Netzauswahl ausgeschlossen
- Training: Masken auch für Zufallszüge und Lernziel

Echtes Beispiel: Einheit vor einem Asteroiden

stehen	51,0	
hoch	51,3	
rechts	**52,2**	**✓ gespielt**
runter	~~53,8~~	✗ Asteroid
links	~~51,2~~	✗ Kartenrand
Sap	~~47,6~~	✗ kein Gegner

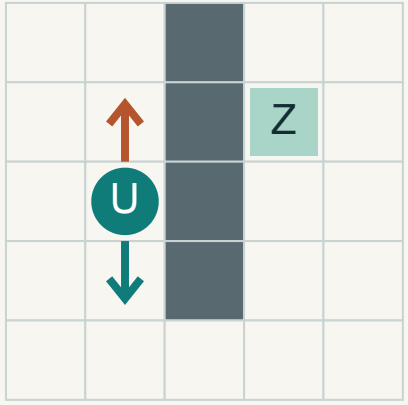
Mittel der 36 Netze. Am liebsten „runter“, das ist aber verboten.

Danach kann eine Regel einen Blindschuss auslösen: Sie prüft ein verdecktes Ziel, Reichweite und Energiereserve separat. Die Maske enthält Spielgrenzen und programmierte Sicherheitsregeln.

Regelkorrekturen

1 · Weg zum bestehenden Ziel

Ein Zug verkürzt die direkte Entfernung, aber nicht den begehbaren Weg um Hindernisse.



U = Einheit · Z = zugewiesenes Ziel

Gewählt: hoch ↑
Direkt: 3 → 2 Felder
Begehbar: 7 → 8

Korrektur: runter ↓
Begehbar: 7 → 6

Das Ziel bleibt gleich. Wenn möglich: erlaubter erster Schritt auf dem kürzesten begehbaren Weg.

2 · Verdecktes Ziel beschießen

Ein Halter würde stehen. Gegnerpunkte deuten auf verdeckte Besetzung. Passendes Punktefeld in Reichweite und genug Energiereserve?

Dann: STEHEN → SAP

Eigene Prüfung; der genaue Aufenthaltsort ist nicht sicher bekannt.

3 · Überflüssigen Schuss verhindern

Andere eigene Einheiten haben bereits genug Schaden auf dieses Ziel geplant?

Dann: SAP → STEHEN

Kein erneuter Netzentscheid.

Nach der maskierten Netzauswahl; ausgewählte Regeln in Ausführungsreihenfolge. Weitere Sicherheitsprüfungen können folgen.
Karte schematisch; Wege nach aktuellem Kartenwissen. Das Ziel wird vorher zugewiesen.

Neu seit letzter Woche

Version	Was Sherlock jetzt anders macht	Schritt im Ablauf	Solution_92
V11 · 30.10.	**36 statt 18 Netze:** 18 nachtrainierte Kopien ergänzen die Originale. Dazu Streuschüsse bei sicher vollem Streuschaden	**4** Netze **6** Regeln	**89,6 → 94,1 %**
V12 · 31.10.	**Blindschuss:** Gegner punktet unsichtbar → vermutetes Punktefeld beschießen. Streuschüsse auch bei halbem Streuschaden	**6** Regeln	**93,0 → 94,4 %**
V13 · 01.11.	**Nebel-Korrektur:** Energie 0 ist kein Beleg mehr für „Nebel kostet nichts“. Nebel nur mit Energie für die ganze Durchquerung	**1** Gedächtnis **6** Regeln	**94,2 → 95,0 %**[1]
V14 · 01.11.	**Kandidaten-Rettung:** 30 Schritte nach dem ersten Relic kein Punktefeld bekannt → Einheiten testen Kandidatenfelder gezielt	**1** Gedächtnis → **6** Regeln	**94,9 → 95,4 %**

02.–04.11. geprüft: kleinere und größere Ensembles, Einzelnetz-Schüler, weiteres Nachtraining. Bester Schüler A2: 38/40 gegen Solution_92 wie V14, direkt gegen V14 aber nur 14/40. **Kein Kandidat nachweislich besser → im Battle spielt V14.**

Siegquote gegen Solution_92, je Zeile eigener gepaarter Vergleich mit der Vorgängerversion auf neuen Karten, beide Seiten: 800 Karten = 1.600 Spiele. [1] V13 auf 300 Karten mit starkem Nebel; nur dort ändert V13 etwas. V14 trotz zweier verfehlter Übernahmehürden per Teamentscheidung übernommen.

Im Battle

Wissen sammeln → Bewerten → Gemeinsam handeln

DAS MACHT SHERLOCK BESONDERS

- Erschließt wie ein Detektiv aus dem Punktestand, welche Felder Punkte bringen
- 36 unterschiedliche Netze bewerten gemeinsam, Maske und Regeln sichern ab
- Schießt auch auf Gegner, die es nicht sieht

WAS WIR GELERNT HABEN

- Netze und Regeln ergänzen sich; gezielte Fehlersuche brachte große Fortschritte
- Nur neue Karten zählen: Eine Regel brachte auf alten Karten +1,8, auf neuen –0,35 pp
- Mehr Netze oder mehr Training ist nicht automatisch besser

Abgegebener V14: 95,4 % Siege gegen Solution_92

Historischer Test: 800 neue Karten × beide Seiten = 1.600 Spiele.

Fragen?

Reserve: Trainingsdetails

Gruppe	Netze	Spiele je Netz	Gegner nach 25 % Aufwärmen gegen default
A	6	3.000	abwechselnd default und Solution_92
B	6	4.000	70 % Solution_92, Rest default
C	6	4.000	60 % Solution_92, 20 % eigene alte Agenten; Strafe für Gegnerpunkte
Nach-training	18 Kopien	+ 5.500	damalige V10-Regeln aktiv; 70 % Solution_92 und zwei Varianten, 20 % eigene Abgaben, Rest default und Rush-Bot

- **66.000 + 99.000 Trainingsspiele** für die Netzfamilien der Abgabe; weitere Projektversuche separat
- Dueling: 79 → 256 → 256; Wert-Kopf 128 → 1 und Vorteil-Kopf 128 → 6
- Reward pro Schritt: Punktefeld halten, Annäherung, Erkunden; Abzug bei Tod. **Matchbonus am Matchende.**
- Double DQN, Replay Buffer mit 300.000 Übergängen; Q = V + A – Mittelwert(A)

Reserve: So prüfen wir

- **Entwicklung:** 300 Karten, beide Seiten, gegen 6 Gegner, darunter 2 RL-Gegner, gegen die nie trainiert wurde. Was auf diesen Karten entwickelt und ausgewählt wurde, sieht dort zu gut aus; entscheidend sind neue Karten.
- **Auswahl:** 200 neue Karten je Kandidat, höchstens einer kommt weiter.
- **Vorab festgelegte Hürden:** frische Karten, Panelgewinn mit positiver 95-%-Untergrenze, begrenzte Verluste gegen Solution_92/default und Direktduell-Untergrenze über 50 %. Im Battle-Protokoll: mindestens +1 Prozentpunkt im Mittel über 6 Gegner. Umfang und genaue Grenzen stehen jeweils vor dem Vergleich fest.
- **V14 war eine dokumentierte Ausnahme:** Panel +0,86 statt mindestens +1 Prozentpunkt (Intervall +0,48 bis +1,28); Direktduell 50,6 % mit Untergrenze 49,25 statt über 50 %. **Zwei Hürden verfehlt**, Übernahme per Teamentscheidung. Spätere Kandidaten wurden nicht übernommen.
- **Statistik:** gepaarter Bootstrap über ganze Karten (beide Seiten zusammen). **Frische Karten:** jeder Block nur einmal benutzt; alte Abgabe vor jeder Übernahme mit Prüfsumme gesichert.

Reserve: Spielregeln, die wir nutzen

Sap (Schuss)	im ganzen Quadrat bis zur Reichweite (3–7); Ziel verliert die Schusskosten, Nachbarfelder einen Anteil (Streufaktor 0,25 / 0,5 / 1, verdeckt)
Kollision	Stehen Einheiten beider Teams auf einem Feld, überlebt nur das Team mit mehr Gesamtenergie; bei Gleichstand sterben beide
Energie-Sog	Benachbarte Gegner ziehen Energie ab (Faktor verdeckt, 1/16 bis 3/8)
Drift	Asteroiden und Nebel verschieben sich alle 7–40 Schritte diagonal
Relics	bis zu drei Paare; ein neues Paar kann in Match 2 und 3 in den ersten 50 Schritten erscheinen
Lage der Relics	auf den höchsten Werten eines Zufallsrauschens mit 6er-Raster: 97 % liegen auf Zeilen oder Spalten mit Rest 2 oder 3 (geteilt durch 6); spätere Paare meist direkt neben früheren (10.000 Karten gezählt)
Punktefelder	je Relic 5 × 5 Felder, jedes mit 20 % Wahrscheinlichkeit; bei zwei Relics in unserer Kartenmessung ca. 34 %