Was Sherlock bekommt und zurückgibt

Eingang in jedem Schritt

- Sichtbare Einheiten beider Teams: Position, Energie
- Sichtbare Felder: Energie, Nebel, Asteroid
- Sichtbare Relics
- Punkte im Match, gewonnene Matches, Schrittzähler
- **Unsichtbar: welche Felder Punkte bringen**

→

Sherlock

höchstens 11,4 ms pro Schritt

→

Ausgang

16 × 3 Zahlen, je Einheit **[Aktion, dx, dy]**

0	stehen
1–4	hoch, rechts, runter, links
5	Sap (Schuss) auf Feld (dx, dy)

Einmal pro Spiel kommen Zugkosten, Sap-Kosten, Sap-Reichweite und Sichtweite dazu. Verdeckte Werte wie den Energieabzug im Nebel schätzt Sherlock aus den Energieverläufen der eigenen Einheiten.

Ein Spielschritt: wer macht was?

1 Gedächtnis
Karte, Relics und Punktefelder über alle 3 Matches
PROGRAMMIERT

→

2 Ziele
jede Einheit ein eigenes Ziel, nach Weglänge verteilt
PROGRAMMIERT

→

3 Merkmale
79 Zahlen je Einheit: Lage, Ziel, Umgebung, Gegner
PROGRAMMIERT

→

4 18 Netze
bewerten die 6 Aktionen mit Q-Werten, wir mitteln
GELERNT (DQN)

→

5 Maske
verbotene Aktionen streichen, beste erlaubte nehmen
PROGRAMMIERT

→

6 Regeln
korrigieren Sackgassen, Nebel, doppelte Schüsse
PROGRAMMIERT

→ **16 × 3 Aktionen ans Spiel.** Das Netz entscheidet **was** eine Einheit tut, beim Sap auch **ob** geschossen wird. **Wohin** geschossen wird, berechnet eine Formel: das Feld mit der meisten getroffenen Gegnerenergie.

Action Masking: nur erlaubte Aktionen

Aktion	erlaubt, wenn …
Stehen	immer
Zug	genug Energie, Zielfeld auf der Karte, kein Asteroid
Zug, im Spiel	zusätzlich kein mindestens gleich starker Gegner auf oder neben dem Zielfeld
Sap	Gegner in Reichweite und genug Energie

- Verboten heißt: Q-Wert = −∞, die Aktion wird nie gewählt
- Im Training gilt dasselbe für Zufallszüge und das Lernziel

Echtes Beispiel: Einheit vor einem Asteroiden

stehen	47,4	
hoch	47,8	
rechts	**48,6**	**✓ gespielt**
runter	~~50,4~~	✗ Asteroid
links	~~47,4~~	✗ Kartenrand
Sap	~~42,2~~	✗ kein Gegner

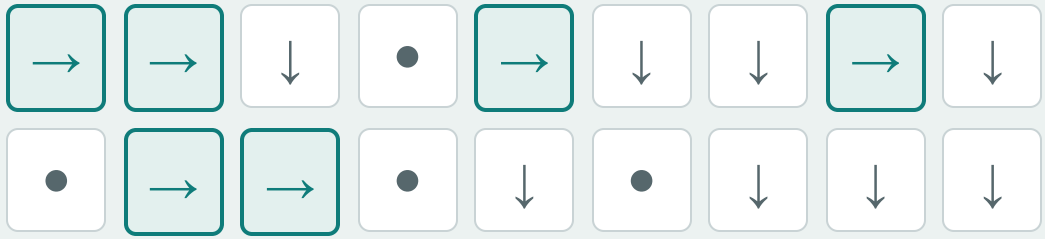
Mittel der 18 Netze. Am liebsten „runter“, das ist aber verboten.

Gemessen in 36.258 Entscheidungen: im Mittel 4,3 von 6 Aktionen erlaubt; in 20 % war die Lieblingsaktion der Netze verboten (10 Spiele gegen Solution_92, 5 Karten × beide Seiten).

18 Netze entscheiden gemeinsam

- **Keine Aufteilung auf Spiele:** alle 18 Netze bewerten jede Einheit in jedem Schritt
- Gleiche Bauart: 79 → 256 → 256 → 6 Q-Werte (Dueling-DQN, 153.000 Parameter je Netz)
- Ein Netz für alle Einheiten und beide Seiten: die Karte wird für Spieler 2 gespiegelt
- Q-Werte je Aktion mitteln → beste erlaubte Aktion
- **Warum 18?** Einzelne Netze schwanken stark, der Mittelwert glättet. 30 Netze waren nicht besser.

Echtes Beispiel: die 18 Netze sind uneinig



→ rechts **6** ↓ runter **8** • stehen **4**

Mehrheit wäre **runter**. Der Mittelwert wählt **rechts** (25,9 vor 25,8), weil er zählt, **wie sicher** sich jedes Netz ist.

In den 36.258 gemessenen Entscheidungen: alle 18 Netze einig in 32 %; im Mittel wählen 13,4 von 18 Netzen einzeln dieselbe Aktion wie das Ensemble; Mittelwert und Mehrheitswahl unterscheiden sich in 8 %.

So wurden die 18 Netze trainiert

Gruppe	Netze	Spiele je Netz	Gegner nach 25 % Aufwärmen gegen default
A	6	3.000	abwechselnd default und Solution_92
B	6	4.000	70 % Solution_92, Rest default
C	6	4.000	60 % Solution_92, 20 % eigene alte Agenten; Strafe für Gegnerpunkte

- **66.000 Trainingsspiele**, je Netz eigener Zufallsstart und eigene Karten
- Double DQN mit Target-Netz und Replay Buffer (300.000 Übergänge)
- Belohnung **in jedem Schritt pro Einheit**: Punktefeld halten, Annäherung ans Ziel, Erkunden, Matchsieg; Strafe für Tod
- Verwendet wird der Endstand jedes Laufs

Das Netz entscheidet, Regeln sichern ab

92 %

der Entscheidungen spielt Sherlock genau so, wie die Netze sie getroffen haben

Eine einfache Regel statt der Netze gewann am 19.10. nur 3 % gegen Solution_92, mit Netzen 38 %.

Regel greift ein	Anteil
Nur Erkundungsziel: direkt hinlaufen statt warten	4,3 %
Schädlichen Nebel umgehen	1,2 %
Kein Schuss auf ein schon sicher getroffenes Ziel	0,9 %
Sackgasse: kürzesten Weg nehmen	0,6 %
Auf dem Punktefeld stehen und schießen	0,5 %
Aus sicherer Entfernung in eine Gruppe schießen	0,25 %

Anteile an 36.258 Entscheidungen in 10 Spielen gegen Solution_92. Zusammen ändern die Regeln 7,3 % der Aktionen.

Reserve: Wie das Gedächtnis Punktefelder findet

Beispiel für einen Schritt

Punktezuwachs in diesem Schritt	3
besetzte Felder	4
davon schon bewiesene Punktefelder	2

Also: von den 2 übrigen Feldern bringt genau 1 einen Punkt

- Solche Gleichungen werden gesammelt, bis sie eindeutig sind
- Die Karte ist spiegelsymmetrisch: ein bewiesenes Feld gilt auch für sein Spiegelfeld
- Gezählt wird erst, wenn die Relics sicher erschienen sind, sonst entstehen falsche Schlüsse