Sherlock

Lernen mit Gedächtnis

Ein Double-DQN-Agent für Lux AI Season 3

Mahmoud El-Hassan · Moayed Shawesh
HTW Berlin · Anwendungen der KI · 16.10.2026

Agenda

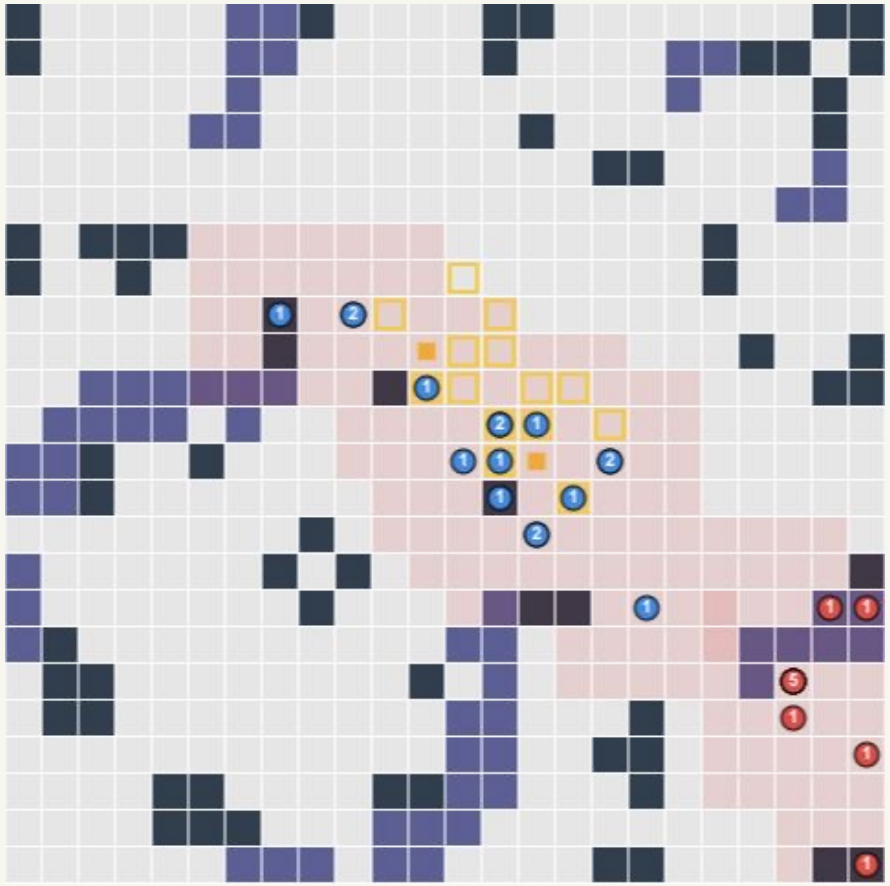
1. Spielidee und Ziel
2. Agent und Merkmale
3. Netzarchitektur und Lernverfahren
4. Training und Auswertung
5. Ergebnisse und Spielbeispiel
6. Erkenntnisse und Ausblick

Spielidee und Ziel

- **24 × 24 Felder**
- **Bis zu 16 Einheiten pro Team**

- Erkunden: Informationen fehlen
- Planen: Energie ist begrenzt
- Punkten: unsichtbare Felder besetzen

- **Kurs: 3 Matches je Spiel**



Unser Agent

Merken

Beobachtungen im Gedächtnis sammeln.

Bewerten

Sechs Netze schätzen den Aktionsnutzen.

Handeln

Die beste erlaubte Aktion auswählen.

Ablauf beim Spielen · Pseudocode

```
FÜR jeden Spielschritt:
    Belief mit Beobachtung aktualisieren
    FÜR jede aktive eigene Einheit:
        x = 79 Merkmale berechnen
        Q = Mittelwert der sechs Netze(x)
        a = beste erlaubte Aktion aus Q
        Aktion für die Einheit speichern
    Aktionen zurückgeben

# Auswertung: kein Lernen, ε = 0
```

Merkmale und Gedächtnis

Merkmalsgruppe	Beispiele
Eigene Einheit	Position, Energie, mögliche Bewegung
Umgebung und Gedächtnis	Gelände, Relics, bekannte Punktefelder
Ziele und Gegner	Zielrichtung, Belegung, Sap-Möglichkeiten
Spielkontext	Matchfortschritt und Teamzustand

Belief: aus dem Punktezuwachs ableiten, welche Felder Punkte bringen.

Netzarchitektur und Ensemble

79 → 256 → 256

Pro Einheit · gemeinsame MLP-Schichten mit ReLU

Dueling-Kopf	Schichten	Ausgabe
Zustandswert V	256 → 128 → 1	Ein Wert für die Situation
Aktionsvorteil A	256 → 128 → 6	Ein Wert pro Aktion

Ensemble: 6 Netze (3 + 3 mit Symmetrie) → Q-Mittelwert → Aktionsmaske

Double DQN

Erfahrungen

Zufällige Erfahrungen aus dem Buffer ziehen.

Lernen

Online-Netz wählt; Target-Netz bewertet.

Belohnung

Punkte, Matchsieg und Shaping-Signale.

Double DQN · Pseudocode

```
BEI jedem Lernupdate:
    Batch = 256 Übergänge aus dem Buffer
    FÜR jeden Übergang (s, a, r, s', Ende):
        a* = beste erlaubte Folgeaktion
             laut Online-Netz
        Ziel = r, falls Ende
        SONST: Ziel = r + γ · Q_Target(s', a*)
    Online-Netz an die Ziele anpassen
    ALLE 500 Updates: Target = Online

# Online wählt, Target bewertet
```

Training und Auswertung

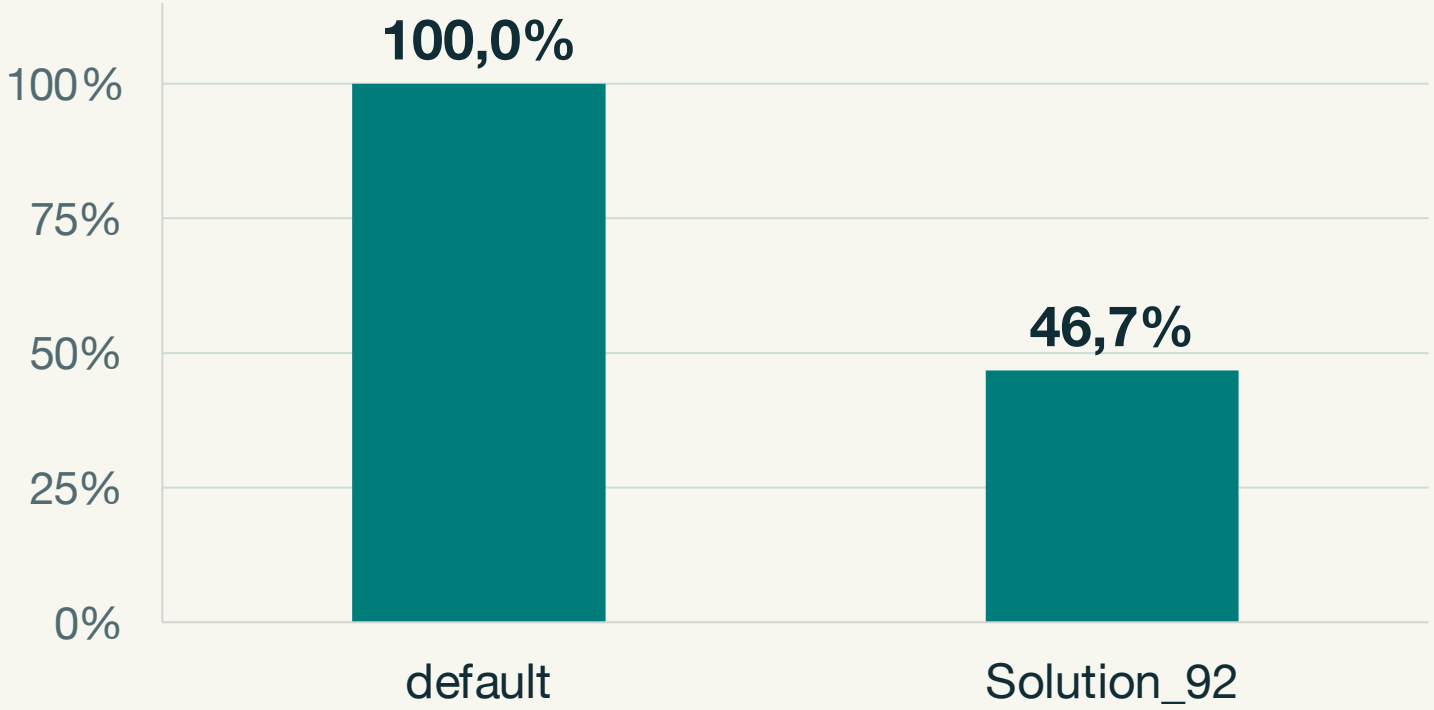
6 × 3.000 = 18.000

Trainingsspiele der sechs Basisläufe des aktuellen Ensembles

Phase	Vorgehen
Training	Erst default; danach default und Solution_92 im Wechsel
Validierung	Getrennte Karten; Checkpoints vergleichen
Auswertung	Beide Seiten; ε = 0; kein weiteres Lernen

Parameter	Wert
Lernrate / γ	0,0003 / 0,99
Batch / Buffer	256 / 300.000 Übergänge
Exploration ε	1,0 → 0,05 in 60.000 Umgebungsschritten
Target-Kopie	Alle 500 Lernupdates

Benchmark-Ergebnisse

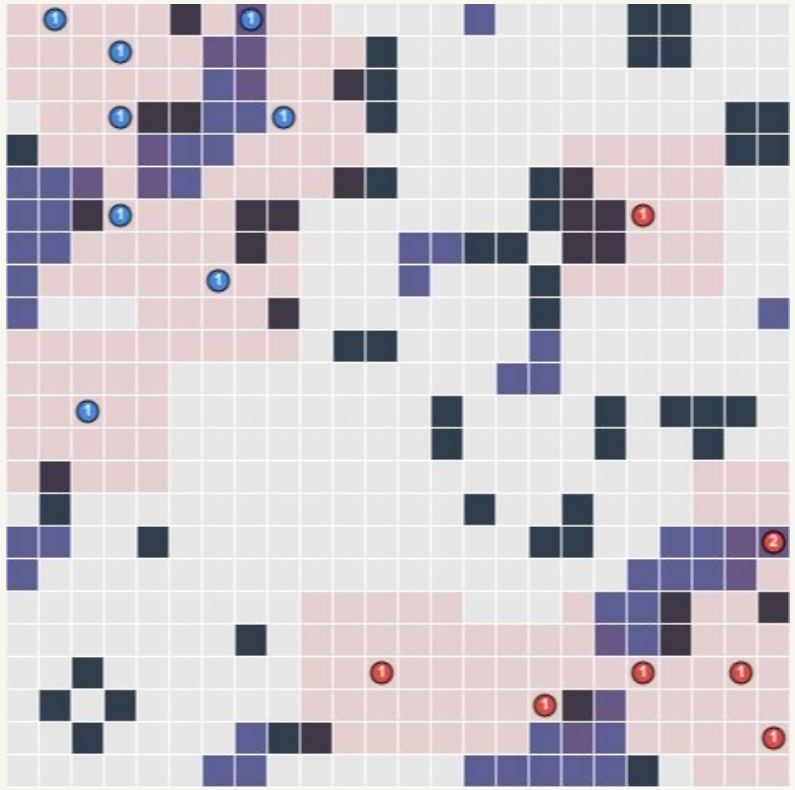


– **60 / 60 Siege gegen default**

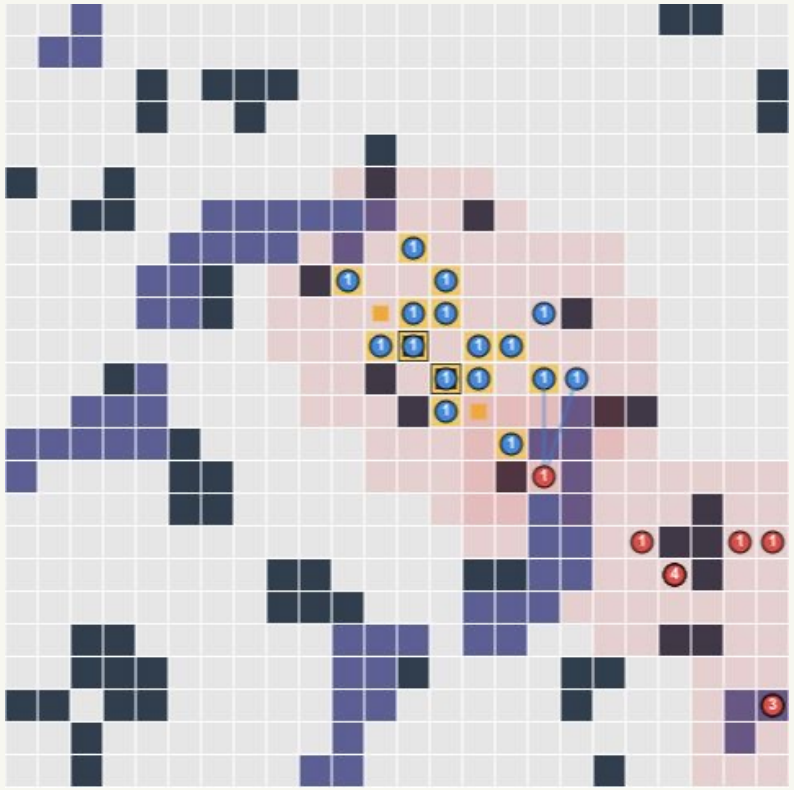
– **28 / 60 Siege gegen Solution_92**

Je Gegner: 30 Karten × 2 Seiten · bereits mehrfach genutzter Benchmark

Spielbeispiel



Schritt 23 · 0 : 0



Schritt 90 · 374 : 11

- **Sherlock: blau**
- **Gegner: rot**

- Blaue Einheiten besetzen Punktefelder
- Stehenbleiben kann sinnvoll sein

Seed 900011 · Match 1
Vollständige Replay-Ansicht

Erkenntnisse und Ausblick

01 Gezielte Verbesserungen wirken

Sechs Netze, Spiegelsymmetrie, Erkundungsgedächtnis: gegen Solution_92 von **12/60 auf 28/60 Siege** (gleiche Testkarten).

02 Mehr Training half kaum

Weitertraining und Self-Play: in unseren Versuchen kein klarer Zusatzgewinn.

03 Nächster Schritt

Match 1 beschleunigen: Relics früher finden, auf neuen Testkarten prüfen.

Fazit und Fragen

Gedächtnis + sechs Netze

– Im Benchmark: 60/60 Siege gegen default, 28/60 gegen Solution_92.

– Nächster Schritt: Frühe Erkundung verbessern und neue Testkarten nutzen.

Fragen?

Trainingsparameter

Parameter	Wert
γ / Lernrate	0,99 / 0,0003
Batch / Buffer-Kapazität	256 / 300.000 Einheitenübergänge
Lernbeginn / Trainingsintervall	5.000 Übergänge / alle 2 Umgebungsschritte
Target-Kopie	Alle 500 Lernupdates
Exploration im Training	ε: 1,0 → 0,05 über 60.000 Umgebungsschritte

Gelernt und programmiert

Gelernt	Programmiert / festgelegt
Q-Werte und Aktionspräferenzen	Belief, Merkmale und Reward Shaping
Gewichte der sechs Netze	Zielzuweisung und erlaubte Aktionen
Bewertung der Aktion Sap	Konkretes Sap-Ziel
Entscheidung aus Netzbewertungen	Mittelwertbildung im Ensemble

Double DQN = Lernverfahren · Dueling = Architektur · Ensemble = Kombination

Belohnung im Training

Signal je Einheit und Schritt	Gewicht
Erste Einheit auf bewiesenem Punktefeld	+1,0
Weitere Einheit auf demselben Punktefeld	–0,3
Annäherung an zugewiesenes Ziel (potentialbasiert)	0,5
Neu erkundete Felder / neue Punktefelder (Team)	+0,3 / +0,5
Energieänderung (÷ 400)	0,1
Einheit verloren	–0,5
Sap: je Treffer / Fehlschuss	+0,3 / –0,3
Match gewonnen / verloren	+2,0 / –2,0